

数据高效语言建模： 从前沿突破到原理指导的模型改进

Qiusi Engine 在 BabyLM 2026 Strict-Small 上的端到端自主研究

杨书行 (Shuxing Yang) 朱凯昊 (Kaihao Zhu) 杨俊杰 (Junjie Yang) 赵瑞 (Rui Zhao)
吴俊尧 (Junyao Wu) 汪易泽 (Yize Wang) 李文浩 (Wenhao Li) 陈福家 (Fujia Chen)
邓韬文 (Taowen Deng) 洪沈展 (Shenzhan Hong) 李亚琪 (Yaqi Li) 李子晨 (Zichen Li)
密金城 (Jincheng Mi) 潘宇昂 (Yuang Pan) 陈红胜 (Hongsheng Chen)* 杨怡豪 (Yihao Yang)*

浙江大学信息与电子工程学院 求是引擎团队

通讯联系*: 杨怡豪 (yangyihao@zju.edu.cn); 陈红胜 (hansomchen@zju.edu.cn)

摘要

在有限数据下，语言模型的进步不仅取决于接触多少文本，还取决于怎样利用其中的信息，以及所学能力能否用于新输入并在后续学习中保留下来。我们报告 Qiusi Engine 在 BabyLM 2026 Strict-Small 上完成的一项长程端到端自主研究。在单个模型至多使用一千万词语料、累计训练曝光不超过一亿词的约束下，Qiusi Engine 贯通前沿突破、原理发现与原理指导的模型改进三个完整研究过程，自主开展文献研究、方法构造、实验执行、评测分析与成果整合。第一阶段联合探索数据、表示、架构和训练，将紧凑重述、预算再分配与残差增量学习结合，建立第一代前沿模型。第二阶段研究经验组织、监督分配、能力复用与保持、学习动力学和测量方法，发现逐字重复与对齐重述会塑造不同的上下文使用方式，其效果取决于目标关系与预测窗口；在受控任务中，熟悉表现的恢复也不保证新输入仍能使用已学计算。这些结果支持一项数据高效学习设计原则：围绕目标预测需要利用的上下文信息及其关系组织经验，分别设计可见信息、监督目标与功能保持，检验模型是否学会所需能力、能否用于新输入，以及继续学习后是否仍然有效。第三阶段据此保留来源文本，扩大局部遮盖，只监督选定目标，并在普通输入上保持已有功能。同一母模型的两轮续训在完整九项评测的 Overall 上均优于普通续训。两代模型的 Overall 从 42.02 提高至 42.25，第二代取得 2026 年 9 月 8 日 Strict-Small 公开榜单的最高 Overall。经验压缩、关系锚点、表示共享和测量控制等研究还形成了可独立使用的发现与方法。模型见 Hugging Face，方法代码、数据构造、评测结果与科研记录见配套 GitHub 工程。这项研究展示了 Research RSI——科研过程的递归自我改进——的一个具体实例：Qiusi Engine 将自身研究形成的科学认识、方法创新与实验经验用于后续问题选择和方法创造，再以新的实践检验和修正这些积累。一次前沿突破由此既产生更好的模型，也改变下一次研究从何处出发、如何探索与判断。

关键词 数据高效语言建模；BabyLM；上下文信息利用；能力保持；自主科研；递归自我改进

目录

1 BabyLM 2026：有限经验学习的研究前沿	4
1.1 有限经验学习的科学问题	4
1.2 研究背景与赛道设置	5
1.3 语言能力与学习行为的评价体系	5
1.3.1 语言形式、知识与上下文使用	6
1.3.2 后续任务中的表示迁移	6
1.3.3 阅读行为与词汇习得	7
1.4 综合评价与排行榜解释	7
1.5 有限经验学习的关键挑战	9
1.6 性能增量与科学贡献	9
1.7 研究价值与应用前景	10
1.8 Qiushi Engine 的三阶段自主研究	10
2 第一阶段：前沿突破	12
2.1 联合选择表示、结构与学习方式	12
2.2 紧凑重述与预算再分配	12
2.3 残差模型与可延续的增量学习	13
2.4 连贯关系与晚期学习	14
2.5 第一阶段留下的科学起点	14
3 第二阶段：原理发现	15
3.1 关系类型塑造上下文使用方式	15
3.2 熟悉表现与新输入上的能力复用	17
3.3 监督分配如何改变关系学习	19
3.4 经验的价值依赖预算、替代对象与能力状态	19
3.5 可操作原则与独立成果	20
4 第三阶段：原理指导的模型改进	21
4.1 从机制判断到可执行设计	21
4.2 分别设计可见输入与监督目标	21
4.3 在普通输入条件下保持功能	22
4.4 完整评测与续训重复	23
4.5 新能力获得与功能保持的机制分析	25

4.6	实践检验如何修正原则	26
5	研究谱系与独立发现	28
5.1	实践继承、问题深化与方法结合	28
5.2	经验压缩、替换与训练阶段	29
5.3	关系锚点、共享表示与可识别性	30
5.4	实体存储、读取与语义寻址	31
5.5	优化、初始化与测量方法	32
5.6	研究全貌的保存方式	32
6	综合讨论	33
6.1	有限经验的价值与上下文依赖	33
6.2	新能力与已有功能的共存	33
6.3	Qiushi Engine 的研究组织与积累	33
6.4	Research RSI: 科研过程的递归自我改进	34
6.5	可复用成果与后续检验	35
7	结论	36
A	训练、测量与复用材料	37
A.1	计算环境与实验支持	37
A.2	模型版本、教师与数据来源	37
A.3	新学习与保持的算法定义	38
A.4	评测聚合、随机性与轨迹	40
B	本地完整评测向量	42
C	扩展机制、控制与独立发现	43
C.1	下游微调随机性的补充比较	43
C.2	目标删除与来源隔离	43
C.3	测量样本与后续更正	44
D	公开前沿的完整分项	45
E	配套研究工程与材料使用	46
F	研究主题与成果目录	48

1 BabyLM 2026：有限经验学习的研究前沿

当语言模型已经能够利用海量文本学习时，为什么还要研究只读过少量文本的模型？这个问题涉及人工智能发展的另一条重要路径：除了扩大训练规模，能否让每一份经验产生更多知识，让已经学到的知识适用于新的表达，并在继续学习时保留下来？训练出一个规模更大的模型，回答了能力可以随资源增长到什么程度；在严格的数据约束下训练出更好的模型，则有助于阐明学习方法本身还有多少改进空间。

BabyLM 为后一类研究建立了公开的共同实验条件。本报告研究其中的 Strict-Small 赛道，并呈现 Qiushi Engine 如何从前沿模型的创造出发，研究有效方法背后的条件，再据此改进模型。两代模型的成绩是这项研究的可见结果；从实验中形成、能够被继续检验和使用的认识，是另一项同样重要的产出。

1.1 有限经验学习的科学问题

语言模型通过预测文本学习。训练先比较模型对候选词的预测概率与文本中实际出现的词，再用一个称为损失的数值衡量预测偏差，据此调整模型参数。本文所说的监督，就是指定哪些预测参与这种学习；监督目标是要求模型恢复的词，监督位置是这些词在输入中的位置。经过反复学习，模型逐渐掌握词语搭配、句法、语义及上下文中的联系。研究还需要辨明：正确预测究竟来自所需的信息关系，还是来自容易利用的局部线索。

例如，前文说明“钥匙从抽屉移到了盒子”，后文询问钥匙现在的位置。模型需要利用前文的状态变化，而不能只依靠“钥匙”和“抽屉”经常一起出现的经验。如果训练中附近词语已经足以猜出答案，模型可以降低预测错误，却很少练习追踪前文。这里的关键区别是：**接触过相关信息，与学会在需要时使用这些信息，是两回事。**

有限数据条件使这一区别更加突出。新增一段文本、重复一段旧文本、把同一内容改写成另一种表达，都会占用训练预算，却未必提供相同的学习机会。重复可以巩固已有模式；不同表达可能帮助模型跨越词面变化；新增来源可以扩展内容覆盖。怎样分配这些机会，需要同时考虑模型已经学会什么、还缺少什么，以及剩余预算允许进行多少学习。数据受限的标度研究也表明，重复使用已有数据的价值需要与不重复的原始数据量及训练配置一起分析 [1]。

“数据高效语言建模”研究怎样更充分地利用有限的学习材料。模型参数量、训练语料量、累计文本呈现量与计算成本分别描述模型容量、材料规模、接触经验的次数与执行代价。小模型也可能反复读过大量文本，较大的模型也可能只有有限经验。BabyLM 的英语严格赛道同时限制语料池规模与累计文本呈现量，让研究者在共同的数据约束下比较数据组织、模型结构和学习方法。

本研究将问题进一步聚焦为：**什么样的训练经验能够让模型学会利用上下文中的信息关系，并使这种能力在后续学习中仍然可用？** 本文将完成预测需要利用的上下文信息及其关系称为**上下文依赖**。这一问题连接了语言学习、组合泛化和持续学习：组合泛化指把学过的成分用于新的组合，持续学习则研究怎样在学习新能力时保留原有能力。后文分别用自然文本、受控关系任务和真实模型训练检验这些问题。

1.2 研究背景与赛道设置

BabyLM 始于 2023 年，2026 年进入第四届，作为共享任务和专题研讨会与 EMNLP 2026 关联。它连接自然语言处理、计算认知科学与语言习得研究，提供训练数据、评价程序、基线模型和公开比较平台 [2, 3]。历届任务总结与论文进一步积累了数据处理、模型构造和学习行为方面的研究 [4]。

这一设置的学术价值来自问题和实验条件，而不只来自榜单。对机器学习研究者，它提供可重复比较训练方法的环境；对语言与认知研究者，它提供观察知识怎样随经验形成的计算模型；对资源有限的研究团队，它使从头预训练、保存中间模型和开展对照实验更容易实施。它并不要求机器完整模拟儿童，而是把受限输入下的语言学习作为机器学习与认知研究可以共同讨论的对象。

2026 年的赛道包括英语 Strict-Small、英语 Strict，以及面向英语、荷兰语和中文的 Multilingual。本报告只研究 Strict-Small，不混合不同赛道的成绩。与本研究直接相关的两级英语预算如下 [5]。

表 1 英语赛道的两个数据约束。M 表示百万；单词数按赛道规则统计，不是模型分词后的 token 数。

赛道	训练语料池上限	累计训练曝光上限
Strict-Small（本研究）	10M 词，即一千万词	100M 词，即一亿词
Strict	100M 词，即一亿词	1B 词，即十亿词

语料池是可以用于训练的文本集合，累计曝光是模型训练过程中实际接触文本的总量。两者不能混为一谈：同一篇一千词的文章读十遍，仍是一篇文章，却已经消耗一万词的曝光预算。改写文本、重复呈现和为保持旧能力而再次输入的文本，也需要按适用规则记账。模型将单词切分为更小的计算单元，这些单元称为 token；一个单词可以对应多个 token，因此模型的分词计数不能直接替代赛道的单词计数。

官方还要求保存中间检查点，即不同训练进度的模型权重，以评价学习过程。外部教师生成文本及其他辅助训练方式有单独的规则，不能仅凭最终词数确认全部条件；本研究的数据和教师说明见附录A。这些要求使比较不仅关心最终得分，也关心模型通过什么经验和训练过程达到该结果。

预算固定之后，研究空间仍然开放。研究者需要选择数据内容与表达形式、词表、模型结构、预测目标、学习率、批量大小、训练顺序和模型选择方法。其中，学习率决定一次更新改变参数的幅度，批量大小决定一次更新汇总多少训练样本；两者都不是越大或越小越好。相同词预算下，更大的批量还可能意味着更少的更新次数。Strict-Small 因而不是一份已经给出全部训练答案的配方，而是一组允许检验不同答案的共同约束。

1.3 语言能力与学习行为的评价体系

一个语言模型能否学会语法、追踪变化中的对象、利用常识、把已有表示用于新任务，以及呈现接近人类的语言行为，需要不同的测量。BabyLM 的九项一级指标分别观察这些能力和行为。**评价体系同时包含语言任务表现与人类行为对应程度，总分汇总的是不同类型的测量。**理解分数时，应先区分每项指标的任务、计算方式和参照水平。

表 2 BabyLM 英语评价的九个一级指标。前七项构成 NLP Average，后两项构成 Human-like Average。具体数值按固定版本的官方兼容实现计算。

指标	主要检验什么	怎样理解分数
BLiMP	能否区分只有细微差别的合语法与不合语法句子	多类语法现象上的选择准确率。
BLiMP Supplement	问答、指称等补充语言现象	多组补充任务单独汇总。
EWoK	能否根据情境调用基本世界知识	比较后续表达在不同情境中的合理性。
Entity Tracking	对象经过移动或更新后，能否找到其当前状态	状态操作后的候选答案准确率。
COMPS	能否把属性用于新概念，并抵抗无关信息干扰	概念属性、继承和干扰条件的比较。
GlobalPIQA	能否判断日常物理行为和用途	不同题型子集的选择准确率。
(Super)GLUE	预训练表示能否支持后续语言理解任务	规定微调后的任务指标均值。
Reading	模型预测能否解释人类阅读行为中的变化	控制词频、词长等因素后的解释增益。
AoA	模型学习词汇的先后是否与儿童习得顺序相关	多个训练检查点上的轨迹相关指标。

1.3.1 语言形式、知识与上下文使用

BLiMP 的最小句对将细微的语法区别单独提取出来，例如主谓一致；EWoK 改变情境，检查模型是否随之改变对表达的判断；COMPS 检查新概念能否继承合适的属性，以及无关概念是否会干扰判断；Entity Tracking 则要求在一连串操作后仍能找到正确状态 [6–9]。这些任务使“句子看起来流畅”与“确实利用了所需信息”能够被分别评价。

例如，句子“The keys are on the table”涉及主谓一致；“钥匙先放进抽屉，随后移入盒子”涉及状态更新；给一种新命名的动物指定类别，再判断它应具有什么属性，涉及概念继承。这里的例子用于解释能力区别，并非实际测试题。它们也说明，小模型的研究困难并不只是背诵事实：有限经验需要支持结构规则、关系使用与状态变化等不同计算。

这些评测通常直接使用预训练模型比较句子或候选答案的得分，不先针对每道题训练模型，称为零样本评测。机会水平取决于题型，不能统一当成 50%。例如，本报告的 GlobalPIQA 英语评测包含 103 道四选一题和 100 道二选一题；两子集等权汇总，均匀随机选择的期望为 37.5 分。因而，同样是 40 分，若题型、机会水平或评分方法不同，所反映的能力也不同 [10, 11]。

1.3.2 后续任务中的表示迁移

(Super)GLUE 测量的是另一种能力：模型经过规定的任务训练后，是否能够支持语言理解。这种在预训练基础上的任务训练称为微调。BabyLM 使用七个任务的选集，包括是非问答、文本蕴含、句子或问题是否同义、多句阅读判断与指代消解 [12, 13]。它检验预训练所得表示能否成为新任务的有效基础。

这些任务有的采用准确率，有的采用 F1。准确率统计答对比例；F1 同时考虑某一类答案预测得是否准确、是否找得完整。因此，(Super)GLUE 不是原版基准的全部任务，也不是全部题目混在一起的正确率。微调随机性、分类头、训练设置和模型选择均可能影响结果，需要在比较中保持一致。

1.3.3 阅读行为与词汇习得

Reading 不考查模型阅读一篇文章后答对多少问题，而是研究模型对词语的预期与人类阅读行为之间的联系。给定前文，一个词出现的概率越低，它对模型越“意外”。这个意外程度用负对数概率表示，英文为 *surprisal*。评价检验它能否在词长、词频等因素之外，进一步解释眼动或逐词阅读时间的变化 [14]。

本文采用 BabyLM 2026 评测程序的评分定义 [11]。若仅使用控制变量时解释的变异比例为 R_0^2 ，加入模型预测后为 R_1^2 ，相应的归一化增益为

$$q = \frac{R_1^2 - R_0^2}{1 - R_0^2}. \quad (1)$$

例如，从解释 20% 增至 24%，增益为 $0.04/0.80 = 0.05$ ，按百分制表达为 5 分。这个公式例子说明了为什么较小的 Reading 数值仍有实际测量含义：它衡量控制变量之外的增量解释量，而非阅读准确率。榜单再按规定汇总不同阅读响应 [15]。

AoA 是 Age of Acquisition，即词汇习得年龄。评价利用多个中间模型上同一词的预测曲线，估计其学习进度，再与儿童词汇习得顺序比较 [16]。本文采用的评测实现计算 Pearson 相关；有效词少于三个或相关检验的 $p > 0.1$ 时记为零，通过门限的负相关则保留负分 [11]。具体评分版本与检查点轨迹见附录 A.4。AoA 为零并不表示模型一个词也没有学会。它与 Reading 一起，使语言任务能力和人类行为对应程度能够被分别研究。

1.4 综合评价与排行榜解释

令九个一级分数为 $m_1, \dots, m_9$ ，七项语言任务的均值为 N ，两项人类行为指标的均值为 H 。Overall Average 的计算为

$$O = \frac{1}{9} \sum_{j=1}^9 m_j = \frac{7N + 2H}{9}. \quad (2)$$

九项分别等权，所以 NLP 与 Human-like 的总权重并不相等。Overall 汇总了不同能力与行为指标，适合按同一协议比较模型；它不能读成“模型只会 42% 的语言”，也不能与大型模型在其他试题、其他训练预算上的得分直接比较。

本研究的两代代表模型分别为 Qiushi-Engine-Frontier-Advancement 和 Qiushi-Engine-Principle-Guided-Frontier-Advancement，下文简称 *Frontier* 与 *Principle-guided*。第一代公开 Overall 为 42.02，第二代提高至 42.25，在本报告保存的公开 Strict-Small 快照中达到最高 Overall。它们展示了从前沿模型到原理指导改进的实际进展。

表3只列两代正式模型，并补入其他发布者中 Overall 最高的八项。这里比较的是公开方法，不列本团队历史提交，也不显示或重新编排排名。快照为 2026 年 9 月 8 日 20:53（北京时间）的公开记录；比较以 Overall 为准，公开榜单与当届比赛奖项的认定是不同事项 [15]。

八项外部提交集中在 40.67 至 41.80，跨度为 1.13 分，相邻条目的差距可低至 0.01。第二代相对外部最高显示分数提高 0.45。接近的总分使方法比较需要更细致的分项分析：哪些能力提高了，哪些发生了取舍，以及同一起点上的重复训练是否仍有收益。公开分数展示前沿位置，后文的共同母模型对照进一步检验训练方案的贡献。

表 3 两代代表模型与八项外部公开提交的比较。模型使用可读简称，完整名称与链接随数据表提供；分数保留公开显示精度。

发布者／模型	Overall	NLP	Human-like
Qiushi Engine / Principle-guided	42.25	53.15	4.10
Qiushi Engine / Frontier	42.02	52.86	4.08
go76dof / WWM curriculum	41.80	52.97	2.71
Serdar404 / RecGPT-10M	41.53	52.40	3.46
Wector1 / Wordpiece-24-4	41.31	52.85	0.92
gyaudhw / compagg relay	40.94	51.81	2.92
gyaudhw / compagg relay (s0)	40.93	51.79	2.92
svsatheesh / BabySteps	40.86	53.59	-3.72
qyxu1994 / instanton-hybrid	40.78	51.53	3.18
gyaudhw / synonly (s0)	40.67	51.46	2.91




图 1 BabyLM 2026 Strict-Small 公开模型的 Overall 比较（2026 年 9 月 8 日）。展示两代 Qiushi Engine 模型与八项外部提交，点及其标签表示公开分数；比较对象与表3一致。

总分相近还可能隐藏不同的能力结构。比较组中，最高 NLP 为 53.59，却因人类行为指标较弱而未取得最高 Overall。BLiMP 为 67.13–73.11，Entity Tracking 为 16.59–29.40；GlobalPIQA 为 36.08–40.68，接近其 37.5 的随机参照。这些差异表明，句法偏好、动态状态与物理常识尚未同步解决。附录D保留全部九项分数，避免让一个总分掩盖各方法的长处与代价。

1.5 有限经验学习的关键挑战

经验覆盖与重复练习之间的取舍。有限的词预算既可以用于更多内容，也可以用于反复巩固已有内容。把文本压缩得更短，可能让更多材料进入预算，也可能丢掉关系线索；改写可能增加表达变化，也可能只制造冗余。研究需要检验哪些处理真正改变了学习，而不能仅按文本数量或流畅程度判断质量。

正确预测与有效信息利用之间的区别。模型可能通过目标附近的搭配完成预测，没有使用相关来源。训练损失下降是真实的，却未必意味着所需关系能力已经形成。为辨明这一点，需要保持预测目标不变，改变可见线索；或保持文本不变，改变哪些词承担学习目标。后文的输入遮盖与监督位置实验正是围绕这两个变量展开。

新能力学习与旧能力保持之间的协调。针对某一种关系训练，可能使模型更会处理这一类题，却损伤普通语言任务。即便熟悉题目的表现恢复，新名字、新表达仍可能无法使用原来的计算。综合改善要求把新能力和已有功能同时测量，不能只在最容易上涨的一个指标上宣布成功。

结构、优化与训练过程之间的相互作用。分词决定文本怎样进入模型；结构决定它能表达什么；学习目标和优化决定哪些关系得到反复训练。一个在早期较好的方案可能在后期失去优势，同样的随机种子也未必使不同结构拥有相同初值。严格比较需要识别这些差别，并选择真正能区分解释的实验。

模型训练与科学研究的不同。一次模型训练在预算内，不代表找到该方法的整个过程只花费同样资源。方案筛选、机制对照、完整评测和误差分析都需要工作。对自主研究系统而言，困难在于连续完成这些环节：保留可靠起点，识别有价值的问题，安排对照，发现错误，修正解释，再将认识转化为可以运行的新方法。Qiushi Engine 的研究能力应从这一连续过程理解，而非仅从最后一次训练理解。

1.6 性能增量与科学贡献

前沿模型的改进需要同时考虑分数、比较条件和科学解释。由于 Overall 是九项均值，某一分项上升 0.9 分、其余不变，会使 Overall 上升 0.1 分；多项小幅变化也可以累积出同样结果。因此，一个小的总分差值可能来自真实而明确的行为变化，也可能受到样本规模、训练随机性或模型选择影响。必须回到分项和对照，才能判断它说明了什么。

本研究不仅比较第一代与第二代，还设置从同一第一代模型出发的普通续训：如果新方案只是多训练一段，它应当难以持续超过这个参照。在两个续训随机种子下，普通续训的完整 Overall 为 42.0926 和 42.1159；密集遮盖、稀疏监督方案在相同累计词曝光下达到 42.2025 和 42.1789。加入普通输入保持的完整方案进一步达到 42.2464 和 42.2317。保持方案增加了部分输入呈现，后文分别说明整体效果与因素归因。

这些成绩的意义不止于位次变化。第一阶段留下了压缩表达并重新分配经验预算的方法、可以继续学习的模型结构，以及完整训练与评测基础。第二阶段进一步发现，不同的重复和重述关系会塑造不同的上下文使用行为，熟悉表现与新输入上的复用也可以分离。第三阶段把这些认识落实为训练操作，并由实际模型结果检验。**科学贡献由新的现象、可区分的解释、可操作的方法及其证据共同构成，不能由榜单差值单独替代。**

研究还考察了少量标签怎样帮助确定关系、新名字怎样与已知对象建立对应，以及显式记忆怎样读取正确状态。这些问题分别形成关系锚点、身份匹配与实体记忆等独立研究方向。它们扩展了对有限经验学习的认识，第5章将分别说明其构造、发现和适用条件。

1.7 研究价值与应用前景

有限数据研究的直接产出是能够被比较和重用的学习方法。专业领域、低资源语言及数据获取受限的应用，常面临高质量训练材料不足的问题。如何保留关键信息、组织互相对应的表达、安排监督与继续学习，因而具有潜在的迁移价值。本研究提供了相应的方法与实验依据，向这些应用迁移是后续可具体检验的方向。

对大规模预训练而言，小规模研究提供了更容易实施的机制实验条件。研究者可以控制数据和训练变量，检查一种方法为什么有效。局部预测捷径、监督分配失衡和保持约束过强等发现，为更大规模训练提供了明确的待检验假设。后续比较可进一步考察这些条件如何随模型规模、任务与预算变化。

对语言与认知科学而言，模型提供了可以操纵输入经验、追踪学习变化的实验对象。语法判断、概念继承、阅读行为和习得轨迹的联合评价，允许研究者讨论“任务表现更好”与“学习过程更接近人类”何时一致、何时分离。模型不是人类学习的完整替身，但清楚的对照可以使两类研究形成实质联系。

对自主人工智能研究而言，本项目将前沿探索、科学认识和方法创造纳入同一个长期研究过程。Qiushi Engine 持续发展数据构造、模型设计与实验方法，也根据新证据调整问题和路线。我们以 Research RSI——科研过程的递归自我改进——描述这种积累重新进入后续研究的过程。第6.4节说明其具体实现、与相关工作的联系及实证范围。

1.8 Qiushi Engine 的三阶段自主研究

Qiushi Engine 主导并执行了贯穿三个阶段的科学研究，包括文献研究、问题与假设形成、数据构造、模型及学习目标设计、实验实现、评测分析和成果整合。团队提供研究目标、资源和阶段性要求，系统在这些条件下持续开展自主研究。计算工作基于 AI Lab 技能与配套科研程序，覆盖数据生成、模型训练、评测和机制实验，由两张 NVIDIA H100 GPU 与 CPU 支持。研究组织见第6.3节，计算环境见附录A.1。

三个阶段围绕同一个科学问题展开，每个阶段都是包含问题提出、假设与方法构造、实验执行、证据分析和成果整理的完整研究过程。它们逐步扩展研究的深度：先在开放的设计空间中创造前沿模型，再从成功、失败与方法分歧中研究学习条件，最后将形成的原理与技术用于新的模型创造。模型、数据、算法和实验方法持续积累，科学解释则接受后续证据的检验与修正。

第一阶段，前沿突破。从有限数据下的模型训练出发，联合探索文本构造、分词与表示、模型结构、优化和训练安排。紧凑重述、预算再分配与残差增量学习逐渐形成可共同使用的方案，经过训练与完整评测产生第一代前沿模型。研究同时留下了数据构造、模型实现和实验基础，以及早晚期效果不同、局部学习与综合表现不一致等需要解释的现象。

第二阶段，原理发现。把第一阶段积累的模型与现象转化为研究对象，提出竞争解释，再通过数据、窗口、监督、表示和内部计算的干预逐步检验。研究涉及经验结构与压缩、表示与归纳偏置、学习信号与能力保持、课程与学习动力学，以及测量和计算实现。关系学习与能力复用形成连接下一阶段的主要认识；关系锚点、身份匹配、初始化对齐和测量方法等研究，也留下了各自独立的发现与工具。

第三阶段，原理指导的模型改进。从已有认识提出新的训练设计，在继承第一代模型和文本的条件下，分别改变预测时可见的信息、承担监督的位置和保持约束。普通续训、不同目标配置、机制检验与完整评测共同检验方案，产生第二代模型，也进一步修正关于监督数量和保持强度的解释。图2概括三个完整研究过程的连续积累。




图 2 Qiushi Engine 的三阶段自主研究。前沿探索、原理发现与原理指导的模型改进各自包含完整研究过程；模型、方法与科学认识在阶段之间积累和发展。研究形成两代前沿模型、数据高效学习原则与开放研究材料。

这些研究支持一项可检验的数据高效学习设计原则（data-efficient learning principle）：围绕目标能力所需的上下文依赖组织有限经验，使相关信息在预测时可用，让监督训练模型利用这些信息，并分别检验能力的获得、复用与保持。获得指学会目标任务，复用指新对象或新表达能够使用所学能力，保持指后续学习后这些能力仍然可用。第3、4章分别说明原则的实验依据、训练设计与作用条件。

2 第一阶段：前沿突破

第一阶段的任务是在严格的数据预算下训练出具有竞争力的语言模型。Qiusi Engine 需要同时解决三个问题：有限文本应怎样安排，模型应怎样构造，以及训练接近预算上限时还能怎样改进。有效方案在文本处理、结构设计和完整评测的反复比较中形成。它最终留下的不只是一组高分权重，也是一套可以继续训练、比较和分析的实验基础。

2.1 联合选择表示、结构与学习方式

模型设计首先要决定怎样把文本变成可学习的对象。字符表示把文字拆得更细，子词表示把常用片段合并；前者需要处理更长序列，后者需要为较多符号学习表示。预测方式也有区别：自回归模型根据前文预测后文，掩码模型则遮盖部分词，再依据未被遮盖的上下文恢复它们。本研究比较了这些选择，以及模型深度、宽度、词表和训练安排的组合。

其他探索包括只激活部分计算分支的稀疏结构，以及给模型增加额外记忆或词面特征。它们有的降低了某项训练损失，但最终需要回答同一个问题：在可比较的预算下，是否提高了所需语言能力？因此，结构比较需要对齐共同参数的初值，分词比较需要重新统计序列和预算，学习目标比较需要同时观察受益与受损任务。研究逐渐从单个部件的局部效果，转向能够共同工作的完整训练方案。

最终前沿路线收束于三项能够共同使用的设计：以紧凑重述重新分配文本预算，以残差结构保留可延续的学习空间，再以完整评测选择晚期增量。其他结构试验仍保留各自结果，详见第5章及附录F。以下沿最终模型的实际形成过程说明这三项设计。

2.2 紧凑重述与预算再分配

训练数据包含原文及相应改写。本文把原文称为“来源”，把保留对应内容的另一种表达称为“重述”；两者组成一个来源—重述对。相关实验材料也将重述称为文本视图（text view），指同一内容的另一种文字表达。第二种表达提供了不同于逐字重复的预测任务，同时也占用词数预算。紧凑重述在保留内容联系的同时减少冗余，将节约的词数用于更多可学习材料。

具体做法是缩短配对文本中的重述部分，再将释放的预算投入更多段落对。核心段落对由 10,094 增至 12,155，增加 2,061 对，约为 20.42%。这项改动发生在语料池内一个大小固定的文本子集，以下称为替换数据块。该块总计 423,520 词，由 261,803 词来源文本、161,708 词紧凑重述及 9 词补齐组成，涉及 4,529 个来源文档；同一文档可以贡献多个段落对。

这项设计同时改变了表达形式和经验覆盖：重述压缩调整了模型需要预测的内容，新增段落对则让同等预算容纳更多来源信息。分开辨明这两种作用，后来成为固定预算替换与目标删除实验的重要问题。

训练中还出现了值得解释的排序变化。为较快比较候选，研究采用 BLiMP、Supplement、EWoK、Entity Tracking、COMPS、GlobalPIQA 与 Reading 的七项均值。这一研究指标包含 Reading、不含 (Super)GLUE，与官方 NLP Average 的七项组成不同。在相应匹配比较中，紧凑重述方案相对参照的差值，在累计 20M 词时约为 -0.83 ，到 70M 与 80M 词时分别为 $+1.29$

表 4 固定词数下的紧凑重述与经验扩展。压缩重述部分后，替换数据块容纳了更多来源—重述对，总词数保持为 423,520。

比较对象	数量	研究含义
原有核心段落对	10,094	配对学习基础
新增段落对	2,061	压缩后重新投入的经验
最终段落对	12,155	较原有数量增加 20.42%
来源文档	4,529	一个文档可提供多个段落对
来源文本／紧凑重述（词）	261,803 / 161,708	保留两种表达的联系
替换数据块总词数	423,520	包含 9 词补齐

和 +1.35。早期劣势转为晚期优势，促使研究把学习阶段纳入数据价值的判断：一种经验可能要在模型形成一定基础能力后，才带来明显收益。

本阶段还研究了连续窗口装填，即把相邻文本按模型可处理的长度组织为训练输入。这类探索积累了词数利用、截断处理和上下文组织方法。最终模型继承了其中明确采用的数据和权重，其他路线则作为独立工程成果保留。

2.3 残差模型与可延续的增量学习

代表模型采用 DeBERTa-v2 风格的掩码语言建模架构 [17, 18]：8 层、隐藏维度 480、8 个注意力头，词表大小为 16,384。隐藏维度是每个位置的内部向量长度；注意力头并行学习从哪些上下文位置提取信息。预测窗口是模型一次处理时可以共同访问的文本范围，主模型预训练采用 256 个 token。分词使用字节级 BPE（Byte Pair Encoding），通过合并常见字节片段构造词表，词表由受限语料训练得到。基本训练采用 15% 的整词遮盖：一个词被选中时，其对应的子词一起遮盖。

残差结构让一条较小的计算支路对原表示作补充。可以把它理解为保留已有计算，再学习一项修正；这里先把 480 维表示压到 128 维，经变换后映回原空间。因此，研究能够控制新增计算的大小，并在后续训练中区分原有参数与新增参数。

在主路径联合训练阶段，残差支路可概括为

$$h' = h + s U \sigma(D \text{ Norm}(h)), \quad (3)$$

其中 h 是原表示， D 与 U 分别压缩和恢复维度， σ 是非线性变换， Norm 为归一化， s 控制补充量。上投影采用零初始化，使新支路在起点不改变原表示；主干与支路随后共同训练。主模型联合训练采用 $s = 1.75$ ，从头学习，不载入外部预训练权重。该构造借鉴了残差与参数高效学习方法 [19, 20]；本研究将其与有限预算下的数据组织、从头训练及后续增量学习结合。

主模型在累计 82,012,495 词曝光时具有 35,463,008 个参数。随后冻结已有参数，增加一条专用的可训练增量分支：共 995,584 个参数、48 个参数张量，最终总参数数为 36,458,592。该阶段使用 101 次参数更新，计入 3,992,800 词曝光，累计达到 86,005,295 词。

增量训练同时使用普通预测损失与 KL 保持项。普通损失训练模型正确预测文本；KL 散度（Kullback–Leibler divergence）衡量两个模型对候选词的预测概率分布有多大差异，保持项通过

表 5 第一代代表模型的主要训练层次。两行属于实际模型谱系，冻结比例不直接代表相同比例的计算节约。

阶段	参数更新方式	总参数数	累计词曝光
主模型联合训练	主模型与残差支路共同学习	35,463,008	82,012,495
冻结基座增量训练	仅更新新增分支	36,458,592	86,005,295

限制这一差异来约束原有预测的变化。第一代已经采用了这一能力保持设计。后续研究在此基础上继续追问：应在什么输入上保持哪些功能，怎样兼顾需要获得的新能力？

专用分支提供了明确的控制方式：关闭新增路径时恢复冻结基座的输出，开启时加入学到的修正。研究在开启状态下评价新旧能力能否共存，并单独记录可训练参数与计算成本。可训练参数约占总量的 2.73%。冻结参数省去了相应参数的更新，但为了训练分布在多层中的增量模块，梯度仍需通过其上方的冻结运算传回；此外还需计算参照模型的输出。因此，参数更新量与实际计算量分别统计。

2.4 连贯关系与晚期学习

冻结基座、只训练增量分支，使研究能够在共同模型基础上比较文本组织。一个关键对照固定起点、增量结构、词曝光和更新数，只打散训练行内的连贯片段。残差尺度为 1.0 时，连贯方案的七项均值为 44.1064，打散方案为 43.1214，差值约 0.9850。相同词语因连贯组织不同而产生明确差异，由此将研究问题推进到文本关系本身。

表 6 晚期学习的参照与对照。七项均值由 BLiMP、Supplement、EWoK、Entity、COMPS、GlobalPIQA 与 Reading 构成。只有最后两行是这里最接近的组织方式对照；普通续训与增量训练还改变了更新参数、优化器和目标。

条件	累计词曝光	七项均值
续训前主模型	82,012,495	43.9594
普通联合续训	86,006,729	43.7707
对应关系打乱的增量训练	86,005,413	44.0129
连贯增量训练（尺度 1.0）	86,005,295	44.1064
行内片段打散的增量训练	86,005,295	43.1214

新增分支在尺度 1.0 下训练，随后比较不同的残差尺度，选择 0.75 作为发布配置。尺度直接乘在增量分支的输出上，0.75 表示向原表示加入该分支输出的四分之三。这是依据评测作出的模型选择。最终第一代的本地完整 Overall 为 42.0240，公开显示为 42.02。

综合指标与逐题行为的变化，引出了增量学习如何兼顾新旧能力的问题。

2.5 第一阶段留下的科学起点

第一阶段留下了可续训的模型、来源—重述材料与三个关键现象：连贯组织优于片段打散，紧凑重述的优势随学习阶段变化，局部改善未必带来整体收益。Qiushi Engine 因而进一步研究关系如何被学会、被新输入调用并在后续训练中保持；配对文本、共同基座和完整评测构成了机制实验的基础。

3 第二阶段：原理发现

第一阶段已经证明，改变文本组织和学习方式可以改善模型。第二阶段把这些实践结果转化为科学问题，围绕经验与表示、学习目标、结构与能力复用、学习动力学和测量方法开展研究。Qiusi Engine 从观察中提出解释，构造能够区分解释的对照，实施实验并根据结果调整认识。研究既形成可指导下一代模型的训练原则，也形成具有独立价值的理论构造、机制分析和实验方法。

本章展开其中两条相互补充的证据链：不同训练经验怎样改变模型利用上下文的方式，以及所学能力能否被新输入使用、能否经受后续训练。前一部分主要使用自然文本，后一部分使用能够精确改变关系和内部计算的受控任务。两类实验共同为下一阶段的训练设计提供依据。其他研究分支按其科学问题在第5章展开，具体方法、实验和结论状态保留在附录F与配套研究材料中。

3.1 关系类型塑造上下文使用方式

逐字重复提供相同表达的再次呈现，对齐重述则把相关内容放入不同表达。两种安排都增加相关文本的接触，但对模型的预测要求不同。若它们只是可互换的信息曝光，则在相近预算下应产生近似的来源利用行为；如果模型练习的是特定的来源—目标关系，收益应依赖后续目标与训练关系是否一致。

例如，来源叙述某个物体的位置，后文用不同句式再次描述该位置。预测后文被遮盖的地点时，模型既可能读取前文，也可能只依据附近词语的常见搭配。若把真实来源换成等长无关文本，目标不变，预测差异就能测量这段来源带来的作用。来源—重述关系因而提供了一类具体的上下文依赖，用于比较训练经验怎样影响后续预测。

各条件共同继承已有改写语料。在此基础上，参照条件不增加所研究的紧凑配对，另外两组分别增加逐字重复和对齐重述，用来比较新增经验的关系类型。研究再为两类配对分别构造同窗与分窗条件：同窗时，来源与对应文本进入同一次预测的上下文；分窗时，保留各自全部材料，但放入不同窗口，使一次预测无法同时访问两者。这样，关系类型的比较与保持文本不变的窗口比较各自对应明确变量。

为直接测量来源的作用，研究保持待预测的词不变，分别提供真实来源、无关来源和长度匹配的普通中性文本。若模型给正确词的概率为 p ，负对数似然 (negative log-likelihood, NLL) 就是 $-\log p$ ；概率越高，NLL 越低，表示预测越好。使用自然对数时单位为 nat。对多个确定的正确目标取平均，得到这里使用的交叉熵损失 (cross-entropy, CE)。记三种输入条件下的平均损失为 T, U, N ，定义

$$A_T = N - T, \quad A_U = N - U. \quad (4)$$

A_T 越大，表示真实来源相对中性文本越有帮助。 A_U 则检查无关来源是否也产生类似变化。两者分别称为真实来源优势和无关来源优势，用来测量指定目标上的上下文作用。例如，真实来源明显改善预测、无关来源变化较小，就支持相关内容本身发挥了作用。

评测进一步按目标 token 是否出现在来源中分组。具体比较的是分词器给出的编号：编号相同即归为重合，否则归为不重合。这种分类测量词面片段的重复，不直接判定完整单词、事实或语义是否新颖。图3采用紧凑重述中 token 不重合的目标。




图 3 训练关系对来源信息利用的影响。a, 真实来源优势；b, 无关来源优势。横轴为相对参照模型的优势变化，单位为 nats，优势定义见式(4)。评测目标为紧凑重述中未在来源出现的 token。点表示三个训练种子的均值，误差线表示种子间标准差。

三个训练种子中，相对参照，逐字重复使该目标类别的真实来源优势平均变化 -0.8138 nats，对齐重述为 $+0.7970$ nats；种子标准差分别为 0.1729 与 0.0758 （图3）。两种经验产生相反方向的效果，而无关来源优势只分别变化约 $+0.0679$ 与 -0.0085 nats。

这一差异究竟来自材料本身，还是来自模型如何共同使用这些材料？表7给出两个种子的窗口对照。对逐字重复和对齐重述分别保留原材料，只把关系两端分开，原来较大的负效应与正效应都明显减弱。文本仍在训练中出现，但不再作为同一次预测的上下文共同发挥作用。这说明，组织有限经验不仅要决定放入哪些文本，还要决定一次预测能利用它们之间的什么关系。

表 7 保持各自配对材料的窗口对照。数值为相对参照的真实来源优势变化 ΔA_T (nats)，采用 80M、90M、100M 词检查点的均值；每个检查点测量 2,732 个来源不重合目标，两列对应不同训练种子。

训练关系	窗口组织	种子 43022	种子 43122
逐字重复	同窗	-0.683	-1.010
逐字重复	分窗	+0.009	-0.134
对齐重述	同窗	+0.712	+0.824
对齐重述	分窗	+0.116	+0.028

英文维基百科与 Simple English 的自然重述材料进一步揭示了目标依赖性。表8使用 1,200 个来源对，分别比较目标 token 在来源中出现与未出现两类情况。对齐重述在句式改变、目标片段仍见于来源的条件下，提高了真实来源的预测帮助；目标 token 不在来源中时，其优势接近参照，而逐字重复产生负效应。这里，训练经验并未带来不加区分的迁移：不同表达中的内容复用与来源外目标预测，对模型提出了不同要求。

表 8 自然重述文本上的关系迁移。数值为相对参照的 ΔA_T (nats)，先在每个来源对的同类目标内平均，再对来源对平均；报告三个训练种子的均值与标准差。每种目标类别均包含 1,200 个来源对，类别按 token 编号是否见于来源划分。

预测目标	逐字重复	对齐重述
目标 token 在来源中出现	+0.109 ± 0.122	+0.238 ± 0.071
目标 token 未在来源中出现	-0.217 ± 0.029	+0.032 ± 0.040

因此，有限经验的价值具有关系选择性：训练中练习的关系与测试所需关系是否相符，会改变迁移的方向。同窗—分窗比较说明关系何时能够参与学习，自然重述比较则说明这种学习能帮助哪些目标。这两组结果共同把“更多相关文本”细化为可以检验的经验组织原则。

这组结果与相关文献构成直接联系。相关文档组织、训练分布与上下文学习之间已有研究 [21–23]。Chen 等通过删除预训练文本中的平行结构，直接研究了同窗关系对上下文学习的影响 [24]；重复也可以促进某些注意力机制的形成 [25]。本文进一步辨明具体关系与目标之间的对应条件：逐字重复和重述在哪些目标上产生不同方向的效果，各自保持文本而拆分窗口后发生什么，以及哪些迁移没有出现同样收益。

3.2 熟悉表现与新输入上的能力复用

模型学会处理一种关系后，新的名字或符号能否使用同样的能力？这要求把熟悉题目的表现与新对象上的关系处理分开测量。本文用“调用范围”描述同一种已学计算能够被哪些输入使用。例如，模型能按熟悉名字选出正确属性，换成新名字后能否继续完成同一操作？研究采用四选一关系任务，分别测量熟悉符号与未见符号，并直接干预与答案选择有关的内部信号。

任务先给出查询对象，再给出四个对象与属性的对应，要求返回被查询对象的属性。可以用“查询 B；A 对应红色，B 对应蓝色，C 对应绿色，D 对应黄色”理解其结构，正确答案为蓝色；这里的词语仅用于解释，实际实验使用受控符号。测试中可以保持关系规则，换成未参与相应关系训练的查询符号，也可以在包含未见对象的上下文中继续查询熟悉对象。后一个比较帮助区分“上下文含有陌生符号”与“模型不能用陌生查询选择正确属性”。

比较中的全序列监督使用序列预测目标，关系答案监督则强调查询答案位置上的预测。静态权重方案固定两类学习信号的相对权重；交替方案轮换关系答案与全序列监督。图4报告用于功能干预分析的两个训练种子（43、100）的均值；这两个种子在初始关系学习后均已表现出未见符号迁移。初始关系学习后，熟悉准确率为 100.0%，未见准确率为 87.5%。普通全序列续训后，熟悉准确率为 87.2%，未见准确率降至 40.2%。静态关系权重条件的未见准确率为 75.5%，交替监督为 83.3%，两者的熟悉准确率均为 100.0%。监督分配因而改变了新符号使用已学关系的能力。

仅比较准确率，还不能知道哪一种内部计算参与了回答。模型在每个属性位置都有一个内部数值表示，称为隐藏状态。研究在第一层比较被查询位置与其他位置的平均隐藏状态，将二者的差归一化，得到一个与位置选择相关的方向。该方向由初始关系模型的 1,000 个拟合样本确定，随后固定用于各续训条件；各类测试分别使用 384 个样本。干预只修改这个方向上的数值，其余分量不变：中心化把四个位置的投影值设为相同，置零删除这一分量，旋转则把这组数值在四




图 4 受控关系任务中熟悉符号与未见符号的四选一准确率。比较初始学习、全序列续训、静态关系监督与交替监督四种设置。点为两个训练种子的均值，虚线表示 25% 机会水平。静态关系监督权重为 1/17；交替监督轮换关系答案目标与全序列目标。

个位置间循环搬移。若删除后答案变差、搬移后答案跟随移动，就能检验这个信号是否实际影响了选择。

初始模型的未见准确率从 87.5% 降至置零后的 25.0%；交替监督条件从 83.3% 降至 38.7%。这些变化说明，被干预的信号对相应任务具有功能作用。旋转之后的目标选择率检验回答是否指向新位置，不应与原题准确率混淆。

表 9 未见符号上的内部功能干预。前三个数值列为原题准确率；最后一列为旋转内部信号后，答案跟随信号指向新位置的比例。所有数值单位为%，采用图4的同一实验设置。

条件	原始	中心化	置零	干预目标选择率
初始获得	87.5	26.6	25.0	67.6
普通全序列续训	40.2	25.1	31.1	31.4
静态关系监督权重	75.5	31.3	33.6	48.2
交替关系监督	83.3	32.9	38.7	63.9

连续训练中的测量进一步区分了能力下降与后续恢复：普通全序列续训先削弱了答案选择信号，随后恢复了熟悉查询对这一信号的使用，但未见查询没有同步恢复。查询熟悉对象时，即使上下文包含未见对象，模型仍可正确使用该信号。这将问题定位到哪些查询能够调用已学计算，而非对陌生上下文的普遍不适应。

研究还检验了一种替代解释：普通续训后，相关信息是否转移到了另一条线性方向？为此，分别从熟悉查询、单个未见查询和两个未见查询的隐藏状态中重新拟合方向，将拟合样本与测试样本分开，再沿新方向替换答案选择信号，以回答转向指定位置的比例衡量干预效果。重新拟合的方向在这里用作干预工具，所测的是它能否控制模型的选择。普通全序列续训模型在这些方向上的未见查询重定向仍弱于交替监督模型，因而没有支持“换一个线性方向即可找回同样功能”的解释。此类内部干预将表示中可读出的信息与实际参与回答的计算联系起来 [26, 27]。

上下文学习在训练中的消退, 以及熟悉与未见 token 上采用不同策略, 已有相关研究 [28, 29]。Dual Process Learning 通过权重遗忘研究这两种策略的共存。本研究进一步改变关系监督的分配, 并用删除、搬移内部信号的实验检查其功能。新增结果具体落在监督条件如何影响复用, 以及哪些内部信号仍能被新符号使用。

3.3 监督分配如何改变关系学习

来源文本出现于输入, 只是关系学习的一个前提。如果重述附近的词已经足以补全目标, 模型可以降低损失, 却很少需要读取来源。监督分配进一步决定哪些预测受到训练、各类预测占多大权重。删除局部线索、改变目标位置或调整损失权重, 都是改变这种分配的操作; 研究需要同时测量关系能力与其他语言功能。

受控实验通过普通全序列监督、关系答案监督、交替安排及匹配有效权重, 区分关系学习与其他预测任务之间的资源分配。关系不匹配的答案监督及单纯降低上下文压力, 不能复现全部目标行为。因而, 结果并不只是“减小总损失”或“增加关系文本”所能概括; 监督位置与被监督的关系是否对应, 是必要的实验变量。

紧凑重述的目标删除实验从另一个方向检验监督内容。来源外目标指目标词没有出现在配对的来源段落中; 复制目标指在来源中能够逐词匹配的目标。研究保留全部输入文本, 分别删除这两类目标中的一部分预测损失。累计 100M 词后, 完整监督条件的七项均值为 43.896, 删除来源外目标为 43.437, 删除匹配复制目标为 42.792。相同输入下, 参与监督的目标集合改变了后续表现。两种删除条件移除的目标数量接近而非完全相同, 完整条件又有更多监督目标, 因此该比较同时涉及监督内容和数量。

另在累计曝光 20M 词的目标删除模型上, 研究测量了不与相应训练来源对重合的局部预测。在 710 个来源对、974 次目标预测上, 删除来源外监督相对删除匹配复制目标, 使被测来源外目标的损失高出 0.0796 nats。按来源对重新抽样, 95% 区间为 [0.031, 0.125]; 进一步要求整个来源文档独立后, 区间包含零, 尚不能确认同样差异。这里的早期局部预测与前述 100M 词后的七项评价回答不同问题: 删去哪类目标会损伤指定内容的预测, 以及不同监督安排如何影响晚期综合表现。附录C分别给出结果。

这些结果说明, 应分别检查输入是否提供所需关系、预测目标是否要求使用该关系, 以及分配给这些目标的学习信号是否足够。输入遮盖与预测比例的分离已有直接研究 [30]; 本研究把这一设计用于来源—重述关系, 检验同样文本怎样因监督位置不同而产生不同学习结果。

3.4 经验的价值依赖预算、替代对象与能力状态

同一种数据是否有价值, 不能脱离它替代了什么。给模型增加一种经验, 同时删去等量另一种经验, 所估计的是一个替换效果。设 A 是加入的经验, D 是被移除的经验, B 为参照训练流, 则在固定训练配置下可以定义

$$\Delta_T(A, D; B) = Y_T(B - D + A) - Y_T(B). \quad (5)$$

其中 Y_T 表示在训练进度 T 的评价结果, $B - D + A$ 表示从原训练材料中移除 D 、加入 A 。比较固定预算、架构、训练日程和随机种子。这个定义将新增数据与被替代数据的作用放在同一比较中, 使“数据是否有价值”成为针对明确参照的实验问题。

研究中的晚期 DeBERTa 比较显示, 视图改造、经验覆盖扩展与精确重复相对各自参照呈现不同效果; 在另一 RoBERTa 配置中, 视图方案虽然改善了自身训练目标, 却没有产生相同的广泛指标收益。文本来源也不是可互换的资源: 固定加入内容后, 移除儿童导向语料还是成人文字, 会改变最终结果。由此应保留的是条件化的认识: 经验价值取决于被替代的信息、学习阶段和模型状态, 不能从一个早期损失或一个文本分布距离推导普遍排序。

这组研究还辨明了结构比较中的初始化混淆。随机种子确定伪随机数序列; 新增网络层会改变这串数被各参数使用的次序, 因此相同种子未必使共同参数得到相同初值。研究显式复制共同参数后, 原先较大的负交互明显减弱。这里的交互指同一种数据处理在不同模型结构上带来的收益差异。该结果说明, 控制共同参数的实际初值, 是判断结构与数据如何共同作用的重要条件。

3.5 可操作原则与独立成果

第二阶段将有限经验学习的设计问题落实为三个可分别操纵的条件: 预测时哪些信息可见, 哪些目标及其权重参与学习, 以及后续训练中哪些已有功能需要保持。自然文本对照揭示关系与窗口的作用, 受控任务揭示能力对新输入的可用范围, 两类证据共同指向输入、监督与保持的协同设计。

这些认识改变了下一阶段要作出的设计选择: 固定监督目标、扩大局部遮盖, 观察模型是否改变对来源的使用; 固定遮盖、增加预测目标, 检查收益是否来自监督数量; 改变保持约束所用的输入, 检查新学习与已有功能怎样变化。Qiushi Engine 将原本围绕高配置的探索, 推进为对信息可见性、监督分配和功能保持的分别设计与检验。第三阶段把这些问题落实到真实模型训练, 并用对照结果继续修正判断。

研究还形成了关系锚点、共享表示空间、身份匹配、实体存储与测量设计等独立成果。第5章说明它们各自研究什么、已验证到哪里, 附录F提供主题目录。主线进入第三阶段时保留的是可以转化为输入、监督与保持操作的认识; 其他有效成果按自身问题保存, 不以是否进入最终模型决定其价值。

4 第三阶段：原理指导的模型改进

第三阶段回到第一代模型。此时已有两项重要认识：文本出现于输入，不保证模型会使用其中的关系；学会一种新行为，也不保证原有功能仍然完好。Qiushi Engine 因此沿用 *Frontier* 的权重、分词器、残差结构和既有文本，重点改变训练任务本身：让哪些提示可见，要求预测哪些词，以及怎样限制对原有预测的破坏。最后再与普通续训比较，判断这些设计是否真正改善模型。

4.1 从机制判断到可执行设计

第二阶段的关系实验表明，来源是否进入预测窗口会改变模型学习到的来源利用行为；监督与功能干预又表明，可见信息不一定被有效使用，熟悉表现也不能代替调用能力的检验。由这些认识出发，真实训练中的设计问题被收束为三个变量（表10）。

表 10 科学认识与训练设计的对应。每项认识落实为具体训练改动，并由相应对照和行为测量检验。

研究认识	训练改动	直接检验
来源可见不保证被使用	保留来源，削弱重述侧的局部线索	固定目标、改变遮盖；测量来源条件差异
监督数量与输入条件是不同的变量	密集遮盖，但仅监督选定的稀疏目标	比较稀疏与密集目标；完成真实模型评测
保持约束可能同时限制新学习	在普通输入上保持母模型功能	比较密集输入与普通输入的新学习、预测变化及任务结果

方案的形成经历了具体的判断更新。早期研究将收益较多地归于增加预测目标；固定稀疏目标后，扩大输入遮盖仍观察到效果，因而转向分别研究可见信息与监督数量。普通输入保持方案形成后，研究再比较不同保持输入与更新幅度，检验它们怎样影响新学习。这是一项逐轮提出判断、设计对照并修正解释的研究，而非在全部实验之前一次性确定整套方案。

4.2 分别设计可见输入与监督目标

来源—重述配对沿用第一阶段已有数据，不在本轮重新生成改写。普通整词遮盖只隐藏部分词，重述内部可能仍保留足够提示，使模型不读来源也能预测目标。新方案保留来源，隐藏重述中的更多候选词，但只选择其中一部分计算预测错误、用于更新参数。候选词按字符位置对应到一个或多个 token，这些一起处理的单元称为内容组。

遮盖与监督分别控制两件事：前者改变模型能看见什么，后者决定哪些位置的预测错误参与训练。一个位置可以被遮盖而不计入预测损失，用来去除其他目标附近的线索。本文的密集遮盖、稀疏监督正是这一安排：扩大线索缺失范围，同时保留较小的预测目标集合。

以 (I, T) 表示输入遮盖与监督目标的组合， S 表示稀疏， M 表示密集。本文将专门选定用于来源—重述预测的位置称为聚焦目标，对这些位置计算的预测损失称为聚焦损失。 (S, S) 与 (M, S) 使用同样的稀疏聚焦目标，区分局部可见线索； (M, S) 与 (M, M) 使用密集遮盖输入，区分哪些遮盖位置承担聚焦损失。图5说明这一差别。

Same source

Mira placed a silver compass against the lantern.




图 5 输入遮盖与监督目标的分离：词级示意。基于同一示例来源—重述对，前两行固定监督目标、改变遮盖范围，后两行固定遮盖范围、改变监督目标。空方框表示被遮盖词，圆点表示计入预测损失的位置。候选内容词参与选择，停用词保持可见；实际选词与分词规则见附录A。

本轮训练文本包含 20,475 行、3,162,742 词。一行是装填成训练输入的文本，可以包含多个片段；用于聚焦关系预测的 3,831 行既有 Qwen 改写，包含 11,778 个配对片段。这些行采用密集遮盖、稀疏监督，其余行继续承担普通语言预测，包括第一阶段的紧凑重述与预算再分配材料。密集遮盖涉及 132,283 个内容组、176,607 个 token；稀疏监督选择 21,479 个内容组、28,590 个 token。因此， (M, S) 中有 148,017 个 token 虽被遮盖，却不计入这部分预测损失。稀疏与密集相对于候选集合定义，确切选择规则见附录A。

新学习目标将关系预测与普通语言预测结合：

$$\mathcal{L}_{\text{acq}} = 0.15 \overline{\text{CE}}_{\text{focus}} + 0.85 \overline{\text{CE}}_{\text{ordinary}}. \quad (6)$$

其中 $\overline{\text{CE}}_{\text{focus}}$ 是选定关系目标上的平均预测损失， $\overline{\text{CE}}_{\text{ordinary}}$ 是普通目标上的平均预测损失。每次参数更新先汇集相应训练行，再各自按全部有效目标 token 取均值，按 0.15 与 0.85 加权；不是先对每行或每个微批次等权平均。这些系数表示两类学习信号的权重，而非文本比例。普通目标使模型在练习关系预测时，仍继续学习更广泛的语言规律。

输入遮盖与预测监督的分离已有直接研究 [30]。本研究将这一设计用于来源—重述关系：来源保持可见，通过遮盖重述侧的局部线索改变预测条件，同时单独选择承担损失的目标。相应对照用于辨明这些操作改变了什么行为，以及能否在第一代模型上产生实际收益。

4.3 在普通输入条件下保持功能

新的训练任务允许模型在大量局部线索缺失时改变预测方式，同时需要保存普通语言输入上的已有功能。保持方案将用于关系学习的既有 Qwen 配对行再次呈现，但改用普通 15% 整词遮盖；更新后的模型与冻结的 *Frontier* 对同样输入和目标位置作预测。两者的概率分布差异用 KL 散度衡量：差异越小，保持损失越低。第一代模型的输出由此成为继续学习中的功能参照。“普通输入”描述这里的遮盖方式，并非另引入一套语料。

具体目标为

$$\mathcal{L}_{\text{pres}} = \frac{1}{|Q_p|} \sum_{(x,i) \in Q_p} \text{KL}(p_{\text{Frontier}}(\cdot | x, i) \| p_{\theta}(\cdot | x, i)), \quad (7)$$

$$\mathcal{L} = \mathcal{L}_{\text{acq}} + \lambda \mathcal{L}_{\text{pres}}, \quad \lambda = 1, \quad T = 1. \quad (8)$$

式中 x 是施加普通整词遮盖后的完整行， i 是该行被选为普通预测目标的位置， Q_p 汇集本次更新中全部保持目标。KL 在这些位置的整个词表概率分布上计算，再按目标总数平均，不约束所有可见位置。 p_{Frontier} 是冻结第一代模型的预测分布， p_{θ} 是待更新模型的预测分布， λ 控制保持约束的权重。温度 T 控制分布计算前的得分缩放，取 1 时不额外缩放。提供参照的模型称为教师，被更新的模型称为学生；这里的教师就是第一代模型。

比较输出时需要排除运行随机性。神经网络训练中的 dropout 会随机屏蔽部分计算，若两个模型使用不同随机状态，即使权重相同，输出也可能不同。因此，保持分支采用确定性计算，并保存、恢复随机数状态，避免额外计算扰动原训练。这使“输出发生变化”主要反映模型更新，而不是比较程序本身带来的随机差别。

以旧模型输出约束后续学习，与 Learning without Forgetting 等方法直接相关 [31]。第一代已经采用 KL 保持项，本阶段进一步研究保持的作用条件：让模型在新的预测任务中学会改变，同时减少普通输入上不必要的功能变化。

第三阶段仍只更新既有增量分支的 995,584 个参数，固定残差尺度为 0.75，不改变总参数量。完整方案采用 80 次参数更新，除新学习曝光外增加 517,332 词普通输入呈现：

$$86,005,295 + 3,162,742 + 517,332 = 89,685,369. \quad (9)$$

无保持分支的对照累计为 89,168,037 词。完整方案额外呈现的 517,332 词，相当于本轮新学习词数的 16.36%，并增加了前向计算。两类方案均在 100M 词上限内；下文将不增加保持呈现的训练设计收益与包含额外保持训练的整体收益分别报告。

4.4 完整评测与续训重复

表11汇总共同母模型和四种训练策略的完整九项评测。每种策略采用续训种子 62064 和 62065，两次训练共享同一预训练起点，改变后续训练的随机过程。普通续训作为实践参照，检验新设计是否产生超过继续训练本身的收益。固定稀疏目标的 (S, S) 则用于输入条件的机制比较，两类对照承担不同任务。

(M, S) 相对普通续训分别提高 0.1099 与 0.0630，在相同累计词曝光下得到一致方向的完整评测收益。完整策略相对普通续训分别提高 0.1538 与 0.1158，相对 (M, S) 再提高 0.0439 与 0.0529。两个密集监督 (M, M) 模型低于同种子的稀疏监督 (M, S) ：在聚焦损失总权重固定为 0.15 时，把监督分配到更多目标，并未带来更好的综合结果。这一区别涉及目标集合及单个目标获得的相对权重。

这些比较给出两个层次的结果：相同累计曝光下， (M, S) 优于普通续训；加入普通输入保持后，完整方案进一步改善。 (S, S) 现有结果为快速评测和机制测量，未列入完整九项表，因此局部遮盖作用的归因应依据相应机制对照，不能由 (M, S) 与普通续训的 Overall 差值单独确定。

表 11 共同母模型与四种续训策略的完整 Overall。两列为同一预训练起点上的续训重复。完整策略包含额外的保持性文本呈现，全部九项分数见附录B。

训练策略	种子 62064	种子 62065	累计词曝光
母模型	42.0240	同一母模型	86,005,295
普通续训	42.0926	42.1159	89,168,037
密集遮盖、稀疏监督	42.2025	42.1789	89,168,037
密集遮盖、密集监督	42.1491	42.1684	89,168,037
密集遮盖、稀疏监督+普通输入保持	42.2464	42.2317	89,685,369




图 6 同一母模型上不同续训策略的完整评测。圆点与三角分别表示续训种子 62064 和 62065，虚线表示母模型的 Overall。各候选均完成九项评测；完整保持策略包含额外的普通输入呈现（表11）。

图7进一步分解完整策略相对母模型的变化。各分项变化除以 9，即为其对 Overall 的贡献。GlobalPIQA 是最大的增益来源，对两个模型的贡献均约为 0.165，占总增量的约 74% 与 79%。实体跟踪等分项也有提高，另一些分项下降；其余八项合计对 Overall 贡献 0.0574 与 0.0428。分项分解说明，新方法的净收益来自具体能力的改善及其间的取舍。

若问新设计比普通续训改善了什么，则需以普通续训为参照。此时，实体跟踪对 Overall 的贡献分别为 +0.1378 和 +0.1511，是两个种子最大的正向变化；GlobalPIQA 均贡献 +0.0572，其他分项合计则抵消部分收益。进一步比较完整策略与不加保持的 (M, S) ，GlobalPIQA 分数完全相同，额外的 +0.0439 与 +0.0529 来自其他分项的净改善。因此，相对母模型的能力增量、相对普通续训的方法收益，以及保持方案带来的附加变化，应分别解释。

对下游微调的补充复核也已有结果：在微调种子 42 和 44 下，完整方案的 (Super)GLUE 均值都高于母模型和 (M, S) 。这项比较固定续训模型、改变下游微调的随机过程，与前述两个续训种子检验不同来源的随机性；三种模型的对应结果见表25。




图 7 完整策略的分项收益与代价。以共同母模型为参照，各分项分数变化除以 9，得到其对 Overall 变化的贡献。圆点与三角分别对应续训种子 62064 和 62065，图中显示点估计。两个种子使用相同评测集合，其中 GlobalPIQA 包含 203 题。

4.5 新能力获得与功能保持的机制分析

为解释保持如何影响新学习，研究在密集遮盖输入上测量三个量：正确目标的交叉熵、该目标在全部候选词中的排名，以及更新模型与母模型的 KL。较低的交叉熵和更靠前的正确词排名表示预测改善；较小的 KL 表示输出变化较少。比较使用已经训练过的 169 个样本，在共同的 1,003 个目标 token 上进行，因此测量的是已训练行为，而非陌生文档上的泛化。

普通输入保持保留了大部分新学到的预测改善；在密集遮盖输入上保持，则显著减小了模型变化，也削弱了对正确词的学习收益。这使保持设计的目标更加清楚：限制普通功能的损伤，同时允许新任务所需的预测改变。研究随后进一步检查，不同输入上的约束实际有多强。

表 12 密集遮盖输入上的新学习与预测变化。除注明 62065 的一行外，续训种子均为 62064。前两个数值列为相对母模型的改善，越大越好；KL 衡量模型输出变化。最后一行将保持约束施加于密集遮盖输入。

方案	CE 改善 (nats)	排名改善	母模型 KL (nats)
普通续训	-0.005	0.7	0.001
不加保持 (M, S)	0.757	132.8	0.503
完整策略, 62064	0.682	128.3	0.353
完整策略, 62065	0.679	128.0	0.345
密集遮盖输入保持	0.159	34.8	0.009

这项比较固定同一更新模型和母模型，在上述共同位置上测量两种输入的差异。密集遮盖使母模型更难预测：表示预测不确定性的熵增加 1.6330 nats，正确目标交叉熵增加 1.3155 nats，两模型间的 KL 增加 0.4738 nats。保持损失对可训练参数产生的梯度大小达到普通输入的 11.835 倍。梯度表示损失要求参数朝什么方向、以多大幅度改变；两个保持梯度的方向相似度为 0.7288，却具有很不同的大小。这解释了为什么使用相同系数不代表施加了同等强度的约束。

表 13 固定模型、共同目标位置上的保持约束比较。更新模型为续训种子 62064 的 (M, S)，参照为第一代母模型。前三项为密集遮盖输入减普通遮盖输入的差值，最后一项为保持梯度大小之比。

共同位置上的比较	结果
母模型预测熵差 (nats)	+1.6330
母模型目标交叉熵差 (nats)	+1.3155
教师到学生 KL 差 (nats)	+0.4738
保持梯度范数之比：密集／普通	11.835

完整保持比较还涉及目标位置的变化：普通遮盖条件有 4,762 个目标，密集遮盖输入上未承担聚焦监督的位置有 6,665 个目标，共同部分为上述 1,003 个位置。结果支持保持配置会改变新学习与旧功能的平衡；输入类型、目标集合和有效约束强度的独立作用尚未完全分离。由此得到更具体的设计要求：保持方案应同时说明约束对象、实际强度，以及新能力和原有功能各自的变化。

普通输入上的另一组测量使用 384 个完整既有文本行、10,348 个目标，保留来源并施加普通整词遮盖。不加保持与完整策略的母模型 KL 分别为 0.02449 和 0.00941 nats；相对母模型的 CE 恶化由 0.0290 降至 0.0100 nats。这组结果显示，普通输入保持确实减小了相应功能变化。该组与表12分别测量普通输入和密集遮盖输入，使用不同样本，各自按共同参照比较。

来源条件干预使用本轮续训文本之后的 96 个来源对、186 个共同目标。这些样本位于本轮训练范围之外，与母模型预训练文档的独立性尚未确认。正确来源下的 NLL 小幅改善，错源、去源条件则出现更明显的预测代价（表14）。完整策略缓解了部分代价，并保留正确来源下的改善。这项测量刻画模型如何响应来源变化，与关系推理的泛化能力分别评价。

4.6 实践检验如何修正原则

第三阶段验证了认识指导训练的实际作用，也使原则更精确。扩大遮盖范围与增加监督目标产生不同效果，支持分别设计预测条件和学习任务。保持约束需要同时检查新学习与普通功能，

表 14 续训种子 62064 的两个模型在不同来源条件下的预测变化。数值为相对母模型的目标 NLL 差值, 单位为 nats, 负值表示改善; 各条件使用同一组目标。

来源条件	不加保持 (M, S)	完整策略
正确来源	-0.024	-0.022
错误来源	+0.149	+0.099
仅保留重述	+0.107	+0.076
完整行中擦除当前来源	+0.210	+0.127
完整行中擦除全部来源	+0.0248	+0.0101

不能单以输出接近旧模型作为成功标准。来源干预则进一步说明, 新模型怎样利用真实来源, 以及在错误来源下付出什么代价。

至此, 三阶段形成了连续的方法发展: 第一代提供成熟模型与关系文本, 第二阶段辨明信息利用和能力复用的条件, 第三阶段据此改变输入、监督与保持方式, 并取得重复的完整评测改善。实际训练结果使科学认识转化为可采用的方法。

新的实践也改变了后续研究应采用的判断依据。固定目标后的遮盖对照, 使输入条件与监督数量得到区分; 共同位置上的梯度比较, 则说明保持系数相同仍可能对应不同的实际约束。Qiushi Engine 因而不仅保留有效方案, 也修正方案的解释, 留下更明确的比较条件供后续研究使用。模型改进、方法积累与知识修正在这里相互联系, 构成第6.4节讨论 Research RSI 的具体依据。

5 研究谱系与独立发现

三阶段研究同时产生了模型改进与独立科学发现。紧凑文本、残差模型和后续训练形成了两代模型的继承关系；围绕关系识别、信息读取与测量方法的探索，则发展出各有实验依据的研究分支。本章说明这些分支解决了什么问题、与主线怎样联系，以及能够供后续研究使用的认识和方法。

这些研究覆盖从文本进入模型、能力逐步形成，到后续学习和结果测量的多个层次。表15按所解决的问题归纳其代表性产出；后文进一步解释经验替换、关系锚点、身份匹配和测量控制等发现。附录F保留完整主题及其结论状态，配套材料提供相应的推导、程序、实验与研究笔记。

表 15 三阶段研究的主要问题与代表性产出。模型方法、机制认识和实验工具分别提供可继续使用的研究基础。

研究层次	具体问题	代表性产出
经验与数据组织	固定预算下，应如何选择内容、压缩表达和安排相关文本？	紧凑重述与预算再分配；固定预算替换；关系类型与预测窗口对照。
表示、结构与先验	文本怎样表示，少量监督如何确定关系并被新输入使用？	字符与子词比较；零初始化残差增量；稀疏锚点、共享表示和身份匹配。
学习信号与能力	哪些预测训练了关系使用，怎样检验计算是否真正参与回答？	输入与监督分离；关系监督分配；熟悉与未见符号对照及内部信号干预。
优化与学习动力学	数据价值如何随训练变化，新能力如何与原有功能共存？	早晚期轨迹、课程与优化器比较；关系经验剂量；增量学习与保持配置。
评测、归因与计算	怎样得到可解释的比较，并保证实现与所研究的方法一致？	共同参数初始化；来源隔离与逐题分析；完整模型加载、预算记账与梯度一致性检查。

5.1 实践继承、问题深化与方法结合

紧凑重述首先是一种预算内的模型改进方法，随后成为可以控制表达关系的实验材料；残差增量结构首先用于成熟模型的继续学习，随后提供冻结共同基座、比较训练目标和功能保持的条件。一个有效方法因而可以同时留下模型资产和新的实验工具。第一阶段与第二阶段的联系，正体现在研究对象得到了持续使用，而解释在新的对照中不断细化。

第二阶段的两条主要分支提供互补证据。自然文本实验研究训练关系如何影响来源利用；受控绑定任务研究查询对象与属性如何对应，以及新符号能否继续使用这种计算。两类实验采用不同任务和模型，共同指向第三阶段的设计问题：让什么信息进入预测，让哪些目标获得监督，哪些已有功能需要在新学习中保持。

第三阶段把这些认识落实为三个训练操作：扩大重述侧遮盖、保留稀疏预测目标、限制普通输入上的输出偏离母模型。最终评测验证了完整方案的收益，进一步对照又区分了目标数量、输入条件和实际约束强度。图8分别标出模型与材料的实际继承，以及机制研究对训练设计的启发。




图 8 模型继承与研究分支。实线表示第二代模型对第一代训练文本、预训练基座和残差结构的继承；虚线表示由实践问题经机制研究形成训练设计的联系。下方归纳经验与训练、关系与计算、比较与测量三个方向的独立成果。

5.2 经验压缩、替换与训练阶段

有限预算下的数据处理有两种不同作用：改变同一内容的表达方式，或者使预算能够容纳更多内容。紧凑重述将两者结合；要研究其原理，则必须分开比较。本研究形成的固定预算替换设计，把“加入什么”与“移除什么”同时作为实验条件。它适用于语料整理、数据混合和课程设计，不局限于一种重述方法。

例如，在同一 DeBERTa 配置的 80M、90M、100M 词模型上，研究比较紧凑重述、从相同来源范围选取不同句子，以及近似逐字重复。对三个训练进度的五项指标作晚期汇总后，相对参照的平均差值分别为 +0.3853、+0.3350、+0.0343。五项为 BLiMP、Supplement、EWOKE、COMPS 与 Reading；不同句子条件扩展的是既定来源范围内的句子覆盖。改变表达和扩展内容在该配置中均有晚期收益，精确重复的作用幅度较小。

替换对象同样重要。固定加入 FineWeb 数据块，移除儿童／口语材料与移除成人散文，在 100M 处的四项均值相差 0.6125 分，前者较低；两者相对参照分别为 +0.0825 与 +0.6950。四项只包括 BLiMP、Supplement、EWOKE、COMPS。加入部分完全一样，却因移除部分不同而产生不同净收益，这是有限经验的机会成本。

另一 RoBERTa 配置中，重述方案改善了自身训练损失，晚期五项差值却为 -0.6873。跨配置比较由此揭示数据价值的条件性：同一类处理在不同模型和训练阶段可能产生不同效果。词频分布等文本统计可以帮助选择候选，最终判断仍来自相应任务上的实际比较。

其他压缩路线进一步区分了词面覆盖与关系完整性。抽取式紧凑视图、词汇范围受控的流畅连接文本和规则改写，分别尝试保留更多内容、补足表达衔接或减少外部生成依赖。短程比较观察到局部收益与任务代价，尚未形成相同完整度的模型结果。其可复用价值在于把压缩质量分解为可检查的条件：保留了哪些词、哪些对应关系、哪些预测线索，以及释放的预算实际去了哪里。

5.3 关系锚点、共享表示与可识别性

有些学习困难来自信息不足以确定答案，而非训练时间不够。假如只知道几个对象分别属于相同或相反的两类，就可以恢复它们的分组，却还不知道哪一组应叫“正类”。给出少数明确标签，才能消除这个命名歧义。这类起定位作用的标签称为锚点。

研究将这一问题落实为二候选关系任务。设事件 i 的关系方向为 $z_i \in \{-1, +1\}$ ，事件间的比较为 $r_{ij} = z_i z_j$ ：取值 $+1$ 表示方向相同， -1 表示相反。对一组经比较相互连接的事件，整体翻转所有方向都不会改变已有比较：

$$(z_i, z_j) \mapsto (-z_i, -z_j), \quad (-z_i)(-z_j) = z_i z_j. \quad (10)$$

一个绝对状态标签可以在这个有限假设类中确定方向。这是稀疏锚点的作用：以少量绝对信息消除仍然存在的歧义，而不是逐项重新监督全部关系。

实验让状态判断和关系比较共享同一套输入表示与序列处理网络，分别使用自己的输出层。实现采用嵌入表示（embedding）和门控循环单元（GRU）：前者将输入符号变成数值向量，后者处理序列中的联系。三个训练种子中，反转少量状态锚点后，未被直接监督的关系也随之反转，按原标签评价的准确率从 1.0 变为 0.0；而这些关系之间“相同还是相反”的判断仍全部正确。也就是说，绝对方向随锚点改变，相对关系得到保留。

变化与不变同时出现说明，少量绝对标签可以通过共享表示影响其他关系，相对结构则得到保留。使用分离表示的匹配模型可以拟合部分局部任务，却没有同样的传递。这一对照使“共享表示”从一般设计偏好变成可以检验的信息传播条件。

表 16 二值关系任务中的锚点反转。两项测量分别检验绝对方向与相对关系，报告三个训练种子的结果，准确率以 0-1 的比例表示。

测量对象	原方向	反转锚点后
未直接监督关系：按原始标签判断	1.0	0.0
未见关系间的相对比较准确率	1.0	1.0

这一构造说明，在给定关系结构中，哪些信息足以确定答案，以及共享表示怎样使这些信息影响其他判断；它与将对象、属性和角色建立对应的绑定表征研究相联系 [32, 33]。这里已经提供候选对象和关系规则。普通文本还要求模型自行发现对象、识别表达中的关系，因此不能把一个锚点在此任务中的效果直接推广到所有语言学习。

名称与对象的匹配是关系使用的另一项前提。即使模型已能计算关系，输入名字仍需要对应到正确对象，本文将这种对应称为身份接口。字符实验提供少量表示“同一字母”的监督，使查询与候选文本的字符表示建立联系。在覆盖全部基础字母的构造中，匹配准确率从 0 提高到 1，并恢复未直接监督事件的关系响应；只覆盖部分字母或训练名字时，含未覆盖字符的新名字仍然困难。

这里的新名字由已经学习的字符组合而成。实验按位置对齐字符，给定候选对象，并在匹配器训练后固定其参数；硬分配指每次直接选定一个候选，而非混合多个候选的表示。在这些条件下，基础字符的覆盖支持了新名称组合的匹配。别名、代词及自由文本指代属于进一步的研究问

题。这一结果将关系计算与输入识别分开，使“学会规则”和“识别规则应作用的对象”能够分别检验。

5.4 实体存储、读取与语义寻址

显式记忆通过模型之外可读写的存储位置保存状态。要用于语言任务，系统需要从文本识别对象，将新状态写入正确位置，覆盖过时内容，再按查询读取所需状态。其中，寻址指确定应写入或读取哪个位置；语义寻址进一步要求依据文本含义作出这一选择。本研究将存储、读取与寻址分开，以定位各环节实际学会了什么。

实验先直接提供正确的写入和读取位置，称为金标准地址条件。可以把记忆槽理解为带编号的存储格：同时重新编号写入和读取位置，不应改变结果；只交换其中一个位置，则会读出不同内容。前一种操作检验结果是否不受编号方式影响，后一种操作检验模型是否真的依赖所读内容。这样便能把“信息存得住”和“模型用得上”分开研究。

将读取结果接入语言预测后，三个训练种子中正确地址条件的答案对数优势 (log-odds) 增益为 1.2056，定向槽交换效应为 2.0513，成对正确率为 0.0472。对数优势比较目标答案与对照答案的相对概率，成对正确率要求一对对应测试都答对。两类读数共同定位了当前能力：记忆已经影响答案概率，可靠完成成对关系判断仍是主要困难。

随后，研究用 $h + gP(m)$ 将记忆加入原表示。其中 h 是模型原表示， m 是读取内容， P 将读取内容映射到相同维度，门控系数 g 控制记忆的加入量；训练还同时降低学习率并延长学习时间。成对正确率提高至 0.1375，槽交换效应为 3.087。这是连接方式与训练设置共同调整后的结果，门控的独立贡献尚未分离。

表 17 实体记忆各环节的实验结果。不同条件分别测量存储内容的作用、地址识别、候选选择与时间状态判断。

研究条件	关键观察	说明的功能层次
给定正确地址	槽交换改变答案概率，成对正确率仍低	记忆影响了预测，完整关系行为仍困难
从自然文本确定地址	总体 token 准确率 90.4%，关键查询召回为零	容易位置上的高分掩盖了查询困难
冻结读取器、学习选择器	词面与角色交换约 0.994–0.995	给定候选中的对应选择已经可用
时间语义选择	原先／更新状态选择约 0.511	理解应该读取哪个时态的状态仍困难

自然文本中的困难促成了选择—读取分解：先训练出能够从指定位置读出内容的模型并将其固定，再训练另一个部分从四个候选位置中选择正确位置。后者使用 softmax 将候选得分转为概率。实验由此区分“内容读不出来”和“内容本来可读、但选错了位置”。模型能较好处理词面与角色交换，却仍难以根据时间含义判断应读取原状态还是更新状态，这进一步明确了尚需学习的内容。

任务检查还发现并排除了一项答案捷径：早期小型实体任务的正确答案不随查询对象改变，模型可依靠固定答案或首个存储位置获得高分。该结果已被撤回，不再作为组合绑定证据；修正语料本身也不构成重新训练后的验证。本章采用的是另行完成的存储、寻址与选择实验。

5.5 优化、初始化与测量方法

结构改动后的比较首先需要确认共同起点。一个删除位置相关注意力项的实验使用相同随机种子，却有 140 个共同张量中的 53 个初值不同；原因是构造顺序改变了随机数消耗。显式复制共同参数后，紧凑视图相对重复的结构交互估计从 -0.6908 变为 $+0.0679$ ，区间跨零，而删减结构本身的绝对能力仍较低。

这一区分明确了结构比较的两个问题：删改结构后总体能力怎样变化，以及同一种数据处理在不同结构上的收益是否改变。前者仍有差异，后者原先较大的交互估计却受到初始化影响。可复用的做法是检查共同参数的名称、形状与实际初值，并显式对齐它们。

优化研究采用了类似的区分。研究通过比较不同目标要求参数改变的方向，检查它们是否互相冲突；再尝试调整冲突方向、加入检测任务或切换优化器。部分调整改善了短程损失或内部测量，却未确认稳定的完整任务收益。它们留下的认识是，更新过程看起来更协调，并不自动表示模型能力提高；是否继续投入，需要以真实任务而非仅优化器内部数值判断。

评测采用两个互补尺度。宏平均先计算各任务分数，再对任务等权平均；逐题分析则比较同一道题在训练前后是否答对。由于任务样本量不同，宏平均提高时，总答对题数仍可能下降。研究分别统计从错变对的题目、从对变错的题目及两者之差，并将 Reading 等非准确率指标单独处理。它们分别说明能力的净收益、获得与损失。

训练工程同样影响科学结论。把文本连续装入有限窗口时，研究核对完整词、来源—重述关系及截断后的实际可见内容。将大批量拆成多个微批量时，需按参与损失的目标数量加权，保持预期的平均损失。激活重计算（gradient checkpointing）通过在反向传播时重新计算部分中间结果节省显存，其数值一致性也需要检查。研究用短程、固定随机性的梯度比较检验这些实现条件；可训练参数比例、最终模型训练成本和寻找方法的研究成本则分别统计。

5.6 研究全貌的保存方式

以上分支形成四类可复用成果：改变真实模型的训练方法，揭示作用条件的机制实验，澄清混淆因素的测量方法，以及具有明确问题与实现的探索性构造。它们分别贡献了可运行的方法、可检验的解释、可靠的比较工具和后续研究方向。

附录F按科学问题收录这些方法、对照和后续修正，并明确标注已有结果与待检验候选。相近方法归入共同主题，便于从问题找到操作、发现和相关章节。图表数据、模型版本与材料入口见附录E。

6 综合讨论

6.1 有限经验的价值与上下文依赖

本研究的核心认识是：有限经验的学习价值，取决于它在预测中提供了什么信息关系，以及训练是否要求模型利用这些关系。文本内容、相对位置、表达形式与预测目标共同构成一次学习机会。同样材料分窗后来源效应减弱，说明关系能否被同时访问具有实际作用；重复与重述对不同目标产生不同效果，则说明训练关系会塑造后续的信息使用方式。

这一认识为数据处理提供了更具体的判断依据。扩展覆盖、精简表达和重复练习分别改变内容范围、预测线索和学习频次；选择方法时，可以检查目标能力依赖什么信息、这些信息是否进入预测窗口、监督是否实际训练这种使用。本研究进一步在既有文本上改变遮盖与监督，在相同累计曝光下取得优于普通续训的结果，将关系研究转化为可采用的训练设计。

相同累计曝光下的方法改善，是本文关于学习效率的直接实践证据。与拟合数据、计算资源和性能关系的标度研究 [1] 相联系，本研究补充了机制与设计层的解释：怎样组织有限经验，怎样检验学到的计算，以及怎样在后续训练中使用这些认识。跨数据量和模型规模的效率变化，可据此进一步建立比较曲线。

6.2 新能力与已有功能的共存

新能力的形成需要改变模型，已有功能的保存则需要约束其中一部分变化。二者应按使用条件协调：在新的关系预测任务上允许学习发生，在普通语言输入上减小不必要的预测偏移。实验中，密集遮盖输入上的强保持压低了新学习收益；普通输入保持则在保留大部分新预测改善的同时，减小了普通输入上的损失变化。

能力保持还包含复用范围的问题。受控任务中，熟悉输入的准确率与未见符号上的关系处理出现明显分离；调整监督分配后，未见符号的表现改善，内部信号干预也改变了回答。结合已有结构性上下文学习研究 [29]，这些结果说明，保持评价需要同时观察熟悉行为和新输入对已学计算的使用。

普通输入保持将这些认识用于真实模型，并在两个续训种子上进一步改善完整评测。该结果验证了完整方案的实用性；保持输入、有效约束强度、更新幅度和额外呈现的各自贡献，是下一步可直接操纵和比较的变量。

6.3 Qiushi Engine 的研究组织与积累

Qiushi Engine 是团队自主研发的分层多智能体科研系统，其基本架构与前期真实光学平台研究见 Yang 等 [34]。核心研究智能体分工承担研究规划、方法构造、实验执行和批判性审阅，支撑子智能体提供资料检索、辅助探索与独立核查。知识系统组织文献、数据和方法资料，记忆系统保存研究进展、实验依据及已形成的方法经验，使后续研究能够继续使用这些积累。各部分共享科研计算基础：团队开发的执行管理与工具接口连接算力和存储等基础设施（Infrastructure）、科学计算环境（Environment）及程序运行支持（Runtime）；AI Lab 为模型生成、训练、评测和机制实验提供可调用的科研工具。

Qiushi Engine 主导了从问题形成到成果整合的连续研究，具体工作随科学问题而展开：查阅文献、构造数据、提出模型与学习方法、实现实验、比较结果、分析机制，并据此决定下一项研究。紧凑重述的早晚排序不同，引出预算与学习阶段的比较；连贯与打散输入的差异，引出关系组织研究；熟悉与未见符号的表现分离，引出监督和保持实验；固定目标后仍观察到遮盖作用，又修正了对监督数量的早期解释。

研究的连续性体现在方法技术与科学认识的共同发展。紧凑重述既改变了训练数据，也为比较不同表达关系提供了可控制的材料；残差增量结构既用于改进模型，也让后续实验能够固定基座、比较不同的学习目标。已有的训练和评测实现被继续使用，关于方法为什么有效的解释则随新实验不断修正。第三阶段因此能够在第一代模型与数据的基础上，进一步设计输入、监督与保持的配合方式。

表 18 研究结果与后续科学决策的联系。观察到的现象形成新问题，并推动相应的对照、机制分析和训练设计。

改变判断的观察	提出的新问题	后续实际研究
紧凑视图的早期劣势与晚期优势	数据价值是否依赖预算和能力状态	固定预算替换、晚期轨迹与跨结构比较
连贯片段与打散材料产生差异	相同词语究竟练习了哪种关系	重复、重述、错源及分窗对照
熟悉行为恢复而未见调用弱	能力恢复的是表现还是调用范围	监督分配、信号抹除与跨位置搬移
密集输入固定稀疏目标仍有效	收益是否必须增加监督数量	输入遮盖与目标集合分别比较
普通与密集保持强度不同	保持配置如何影响获得与保存	共同目标梯度比较及完整方案评测

这些联系体现了长期自主研究的具体价值：已有结果持续改变下一项研究决策，已有材料持续支持新的实验。Qiushi Engine 将方法构造、实验实现、结果分析和解释修正连接起来，使一次模型突破成为后续科学认识与方法创造的起点。

自主科研中的想法生成、实验迭代、分析与写作已有系统研究 [35]。本项目提供了有限数据语言学习中的三阶段案例：从前沿结果中提出科学问题，再让得到的认识改变后续模型训练。开放这条研究链及其材料，可以支持社区研究长期知识积累如何影响自主科研的质量与效率。

6.4 Research RSI: 科研过程的递归自我改进

长程自主研究的积累，不止于保存已经找到的最佳模型。对数据价值的判断、对学习机制的认识、可组合的方法技术和能够区分解释的实验，也会成为下一阶段的研究基础。Qiushi Engine 的三个阶段展示了这些成果怎样共同发展：实践扩展可行的方法空间，机制研究辨明方法的作用条件，新的模型创造则检验这些认识能否转化为实际改进。

我们用 **Research RSI** (Recursive Self-Improvement of the Research Process, 科研过程的递归自我改进) 描述其中的递归关系。持续开展研究的 Qiushi Engine 将自身形成的科学认识、方法创新与实验经验重新用于后续研究，更新问题选择、实验策略、方法构造和证据判断；新的实践再检验并修正这些积累。这里直接更新的是系统开展科研所依据的知识与方法，而非研究代理的参数或代码。一次研究不仅改变系统得到了什么，也改变系统下一次怎样做研究。

本项目中的改变同时涉及研究认识、实验工具和训练方法。紧凑重述的早晚期差异，使数据选择从静态排序转向预算、替代对象和学习阶段的共同比较；残差增量结构从模型改进方法发展

为固定共同基座、研究功能变化的实验工具；关系与能力复用实验进一步促成输入、监督和保持的分别设计。它们没有被压缩成一份最优参数清单，而是以带有作用条件、对照结果和修正记录的方法继续参与研究。表18与表10分别列出判断的演进及其进入训练的具体方式。

新模型取得收益之后，研究仍继续检验设计依据。固定目标后的遮盖比较，修正了“增加监督数量带来改善”的早期解释；共同位置上的梯度比较，则表明相同保持系数可以产生很不同的实际约束。因而，下一轮研究既可使用有效方案，也能利用更准确的比较条件。科研笔记、实验规划、程序与结果保存了这一过程，使读者能够看清一项判断从何而来、怎样进入方法、又被哪些证据改变。这是本案例可解释性的主要来源。

相关研究已经从不同对象探索自我改进：STOP 将程序改进器用于自身 [36]，Darwin Gödel Machine 修改智能体代码并以任务评测筛选改进 [37]，Reflexion 将语言反馈保存在记忆中供后续尝试使用 [38]。Co-Scientist 通过假设生成、辩论、演化和持久记忆组织自我改进循环，并与科学家合作完成生物学实验验证 [39]；近期综述也将科研过程本身列为一种改进对象 [40]。Qiushi 的具体贡献在于，把真实前沿模型的创造、学习原理的发现、原理指导的后续模型设计及完整比较连接在同一研究计划中，并保留各阶段知识与方法如何发展、结合和修正的实证材料。

本案例支持同一 BabyLM 项目内的递归研究闭环：研究积累改变了后续设计，真实模型对照验证了其中具体方案的收益，进一步实验又修正了认识。它尚不等同于跨任务的一般科研能力已持续提升；这一更广问题需要在独立研究目标上比较知识复用对实验选择、研究成本与成果质量的影响。三阶段的意义，是使前沿突破既成为一项研究成果，也成为后续研究可以继承、检验和发展的知识来源。

6.5 可复用成果与后续检验

本研究留下了三个相互联系的贡献：关系类型与预测窗口影响上下文使用的实验发现，监督分配与内部干预揭示能力复用条件的机制研究，以及在真实模型上得到重复改善的训练方案。经验压缩、关系锚点、身份匹配和测量控制等独立研究则扩展了可供继续检验的方法范围。

这些成果在不同层次上提供了可继续研究的起点。自然文本对照揭示关系组织的选择性作用，受控任务通过内部干预解释新输入怎样使用已学计算，真实训练则验证输入、监督与保持设计的实际收益。三类证据相互补充，共同形成从学习现象到方法创造的联系；它们各自的对照范围已在相应实验中说明。独立母模型、不同预算和文档隔离条件下的检验，可以进一步研究这种联系的适用范围。

分项分析进一步说明了方法的实际价值。相对母模型，GlobalPIQA 贡献两个完整方案 Overall 增量的约 74% 与 79%；相对普通续训，最大的正向贡献则来自实体跟踪。加入保持方案后的附加收益来自其他分项的净变化，GlobalPIQA 在这一步保持不变。固定模型后的两种微调种子比较还表明，完整方案的 (Super)GLUE 优势不只见于一微调。区分这些参照，才能解释每一步训练设计改善了什么，而不把一种比较的收益结构套用于所有结论。

当前完整结果来自同一母模型的两轮续训，完整方案增加了保持性文本呈现。GlobalPIQA 仅包含 203 题，两个续训模型使用相同评测集合，逐题配对的不确定性区间尚未随本文提供。因而，本报告的是已有对照下的综合净改善及具体分项变化；训练随机性、评测样本不确定性与跨底座迁移需要分别衡量。

反例与修正也是可复用知识。任务捷径检查、共同参数对齐和文本重合分析，分别排除了答案构造、初始化和样本选择中的混淆。它们帮助后来者建立更可靠的对照，并明确哪些早期解释已被后续结果替代。

成果的使用因此包括模型和研究方法两个层次。两代模型提供实践起点；数据构造、目标定义、对照设计、分项结果和研究笔记说明方法如何形成、怎样继续检验。报告与配套仓库共同组织这些材料，具体文件入口和当前可用范围见附录E。

7 结论

Qiushi Engine 在 BabyLM Strict-Small 上主导并完成了前沿模型构建、原理发现和原理指导改进三个完整研究过程，持续开展问题形成、方法设计、实验执行、机制分析与成果整合。三个阶段围绕同一个科学问题推进：有限文本怎样让模型学会利用上下文中的信息关系，并使新学习与已有语言功能共存。

研究辨明了两个重要条件。逐字重复与对齐重述选择性地塑造来源信息的使用方式，作用取决于目标关系和预测窗口；熟悉输入上的表现恢复，也不保证未见输入仍能使用已学计算。由此提出的设计原则，是围绕目标所需的上下文依赖组织经验，分别设计可见信息、监督目标与功能保持，再以新旧能力的共同表现检验效果。

这一原则进入第二代模型的具体训练，在共同母模型的两次续训中均取得优于普通续训的完整评测结果。两代公开代表模型的 Overall 从 42.02 提高到 42.25。预算再分配、残差增量学习、关系锚点、身份匹配和测量控制等研究，还留下了各有问题与实验依据的独立成果。

对长期自主科研而言，这项工作展示了 Research RSI 的一个具体实例。Qiushi Engine 从自身研究中积累科学认识、方法技术与实验经验，使后续研究能够提出更明确的问题、构造新的方法，并用实际结果检验和修正设计依据。在这一过程中，原有成果既被继承，也成为新的研究对象；有效方法得到发展，失效解释被修正，研究路线在分化与整合中向前推进。

两代模型、学习原理、实验方法与独立发现共同构成可继续使用的研究基础。报告说明它们为何形成、如何相互联系，配套工程保存模型、代码、数据构造、完整结果和科研笔记，使同行能够检验已有认识，并据此开展新的研究。

A 训练、测量与复用材料

A.1 计算环境与实验支持

研究通过 AI Lab 技能及配套科研程序开展计算。这里的技能是一组可供 Qiushi Engine 调用的科研工具，支持模型生成、训练、评测、内部计算分析与干预实验。CPU 用于文本处理、分词、数据统计和结果分析；两张 NVIDIA H100 GPU 用于模型训练、评测、教师文本生成及需要加速的机制实验。已有记录包括在 H100 上运行 Qwen/Qwen3.5-9B，为既有来源文本生成紧凑重述，也包括关系任务训练、隐藏状态和梯度测量、内部信号干预等不同类型的研究计算。

表 19 研究计算平台概要。GPU 配置依据研究记录；CPU、内存和操作系统为 2026 年 9 月 9 日的主机核对值。

项目	配置
GPU	两张 NVIDIA H100
CPU	双路 Intel Xeon Platinum 8473C，共 104 个物理核心、208 个逻辑线程
内存	操作系统可见约 503 GiB
操作系统	Ubuntu 22.04.5 LTS, x86_64

两代模型发布包记录的 CPU 验证环境为 Python 3.12、PyTorch 2.11.0（CUDA 12.8 构建）、Transformers 4.57.6、Tokenizers 0.22.2 和 Safetensors 0.8.0，完整依赖见 `models/frontier/ENVIRONMENT.json` 与 `models/principle_guided/ENVIRONMENT.json`。各项原始训练、生成和评测分别使用相应的程序与依赖记录；上述发布验证环境不替代它们。配套工程在 `reproducibility/TRAINING.md` 中给出环境说明、训练入口和数据依赖。

A.2 模型版本、教师与数据来源

两代公开模型具有相同的总参数量与结构配置；第三阶段更新既有增量分支。掩码预测与下游微调均采用包含相同增量模块的加载实现，才能评价完整模型。输入长度、填充和截断方式由各评测配置显式指定。后文所说的模型版本，包含权重、结构配置、分词器和加载实现这几个相互对应的部分。

共同预训练采用 8 层 DeBERTa-v2 风格结构，隐藏维度 480，8 个注意力头，前馈层维度 1,920；字节级 BPE 词表为 16,384，序列长度为 256。优化器为 AdamW，有效批量 256，峰值学习率 0.001，前 6% 训练线性预热，随后余弦衰减，权重衰减 0.01。初始残差支路的瓶颈维度为 128，尺度为 1.75。模型配置、参数初始化与训练随机过程分别记录种子 43、43022、43023；它们控制不同环节，不应合并成一个未加区分的“训练种子”。第一代后续增量训练与第二代续训的分界见表5，完整记录见 `models/frontier/TRAINING.md`。

以下链接直接指向本文采用的模型版本；完整版本记录随 `results/public_model_revisions.csv` 提供。

Frontier

[Qiushi-Engine-Frontier-Advancement](#)。

Principle-guided

Qiushi-Engine-Principle-Guided-Frontier-Advancement。

本研究涉及三种不同的模型角色：驱动科研过程的推理模型、生成训练文本的外部改写教师，以及提供保持参照的冻结母模型。第三阶段的保持教师是 *Frontier*，沿用的数据则包含此前已生成的 Qwen 改写。数据清单分别列出两部分：37,594 个既有来源—重述对，共 1,656,800 词；12,155 个紧凑重述对，共 423,511 词。它们均计入 10M 词语料池，第三阶段直接使用已有文本。

紧凑配对的 423,511 词指实际来源与重述文本；加上预算对齐的 9 词补齐后，构成表4中 423,520 词的替换数据块。

紧凑重述的生成教师为 Qwen/Qwen3.5-9B，生成温度为 0.1，每次最多生成 80 个 token，批量为 64，计算精度为 bfloat16。这些设置及来源计数记录在 `models/frontier/DATA_MANIFEST.json`。配套工程保留生成模板、配对选取、过滤和装填记录；`data/RECONSTRUCTION.md` 按配对构造、紧凑替换、续训文本选取与位置标注说明重建过程。原生成器由外部程序提供，仓库保留其调用设置与输入输出格式，具体依赖见 `reproducibility/TRAINING.md`。

第三阶段实际使用的训练文本见表20。一行是组织为训练输入的文本，可包含多个片段；表内按行计数，描述本轮训练材料的组成。完整语料池的各来源词数另见数据清单。数据使用同时遵循来源许可、生成材料与累计曝光规则。

表 20 第三阶段训练文本的来源组成。合计 20,475 行、3,162,742 词；一个训练行可以容纳多个配对片段。

来源类别	打包行数	来源类别	打包行数
Gutenberg	3,635	CHILDES	5,173
Simple Wikipedia	2,063	紧凑重述与预算再分配	940
既有 Qwen 来源—重述配对	3,831	BNC spoken	1,108
OpenSubtitles	3,684	Switchboard	41
合计			20,475

A.3 新学习与保持的算法定义

设普通目标集合为 Q_o ，关系聚焦目标集合为 Q_f ，密集遮盖候选集合为 Q_m ，其中 $Q_f \subseteq Q_m$ 。对给定输入 x 与目标集合 Q ，本文的均值交叉熵为

$$\overline{\text{CE}}(x, Q) = \frac{1}{|Q|} \sum_{i \in Q} -\log p_{\theta}(y_i | x, i). \quad (11)$$

其中 y_i 是位置 i 的正确 token， $p_{\theta}(y_i | x, i)$ 是模型在该位置给它的概率， $|Q|$ 为目标数量。 (M, S) 的关系输入按 Q_m 遮盖，损失只在 Q_f 上求均值； (M, M) 使用相同密集输入，但扩大关系监督集合。式中先以一行为例；实际训练在一次参数更新的所有行中分别累加聚焦与普通目标的损失，再各除以对应的目标 token 总数，按式(6)加权。微批次只划分计算，不改变这两个分母。

行的分配由既有数据标注确定：带有来源—重述片段位置的 Qwen 配对行进入聚焦分支，其余行进入普通整词遮盖分支。表20中的 940 行紧凑重述与预算再分配材料属于后者。因此，第一阶段的紧凑文本仍参与普通语言学习，第三阶段的聚焦任务则作用于另一组已存在的配对行。

保持分支只再次呈现聚焦分支所用的 Qwen 配对行，重新施加普通整词遮盖，并在这次遮盖选中的目标位置计算 KL。

内容组先在已有配对的重述文本中定位字符区间，再通过分词器返回的位置对应关系映射为有效 token。候选词由英文字母或数字组成，允许词内撇号；转为小写后，排除长度小于四、纯数字及固定停用词集合中的词。停用词是预先列出的、不参与本次候选选择的词。这是一套词面筛选规则。稀疏监督从每行候选中最多抽取 16 组，再逐组以 0.35 的概率选取；若候选非空但未选中任何一组，则保留一组。

密集遮盖另取候选集合，默认最多抽样 128 组；超过该数量时按行级随机种子抽样，再补入全部被监督组。因此，补回后的集合可能超过 128 组。遮盖和监督分别选择，标签与输入使用同一套位置映射。确切停用词表、行级随机种子的生成规则和来源片段位置应与训练程序一同使用。

完整方案按以下顺序计算。

1. 从固定训练文本中读取完整行，按累计词数安排更新，使用已经确定的来源—重述配对及分词映射。
2. 为标注的 Qwen 配对行构造关系输入及 Q_f, Q_m ，为其余行构造普通输入及 Q_o ；统计本次更新两类目标的总数。
3. 按各自目标总数归一化损失，以式(6)组合并累积梯度。更新集合只包含指定的 48 个增量参数张量，基座参数冻结；若本次更新某类目标为空，程序报错，不改变预定损失权重继续运行。
4. 对同批 Qwen 配对行构造普通遮盖输入及保持目标。冻结教师，以无梯度方式计算其概率；学生在相同位置计算 $KL(p_{Frontier}||p_\theta)$ ，按全部保持目标数归一化并累积梯度。
5. 保持前向关闭 dropout，但学生仍保留梯度计算；确定性运行不等于冻结学生。保存、恢复额外前向后的 Python、PyTorch CPU 与 CUDA 随机数状态，恢复训练模式后完成一次参数更新。
6. 分别累计新学习词曝光与用于保持的文本呈现，保存检查点身份及评测向量。完整方案在 80 次更新后导出。

表21汇总主要续训设置。按词数安排更新，是将完整训练行累积到预定词数后进行参数更新；由于行长不同，每次实际处理的行数与 token 数可以变化。学习率随日程变化，表中最后一次更新值单独标明。

普通续训的目标 token 数为 697,102； (M, S) 的普通目标为 592,858，聚焦目标为 28,590。即使累计词曝光相同，目标数量与目标权重也不同。这正是完整方案比较不能被误写为单独改变一个遮盖比例的原因。

输入长度按具体实验设置：主模型预训练窗口为 256 个 token，最终续训和表13的梯度比较采用 512 的上限。学习率日程的偏移表示从既有日程的相应位置继续计算，不能把这 80 次更新当作重新启动的一套独立日程。实际执行配置见 `experiments/configs/executed_stage3.json`，环境和命令见 `reproducibility/TRAINING.md`；使用时保留各对照自身的目标选择、随机采样和保持设置。

表 21 第三阶段续训的主要配置。两次训练共享母模型、数据处理与方法设置，续训随机种子分别为 62064 和 62065。

配置项	值或定义
母模型	固定修订的 <i>Frontier</i>
总参数／可训练参数	36,458,592 ／ 995,584
增量参数张量／尺度	48 ／ 0.75
词表大小	16,384
续训输入上限／微批量	512 token ／ 8 行
续训种子	62064、62065
参数更新次数	80
每次更新的词数目标	约 39,533 词；按完整行记账
学习率参数／日程	5×10^{-5} ；455 次更新日程、偏移 101、预热 10
权重衰减／梯度范数上限	0.01 ／ 1.0
聚焦／普通损失权重	0.15 ／ 0.85，各自在目标集合上取均值
保持权重／温度／方向	1.0 ／ 1.0 ／教师到学生
保持输入	普通 15% 整词遮盖的完整行，保留来源
新学习词数／保持词数	3,162,742 ／ 517,332
最终更新学习率（62064）	3.4055×10^{-5} ；仅为该更新记录

A.4 评测聚合、随机性与轨迹

完整评测的各项加载接口均包含实际增量分支。零样本掩码预测、Reading、下游微调和 AoA 按各自实现生成结果，再依据式(2)聚合。本地九项比较沿用各次运行的评分报告与统一聚合方式，公开榜单表保留网页显示值；正文的四位小数用于比较接近的数值，统计不确定性按相应测量单独分析。

评分实现以文献 BabyLM Organizing Team [11]所固定的官方版本为参照，AoA 估计器对应修订 6f825c2。配套工程保留实际使用的评分程序，以及为完整增量模型提供的加载适配；reproducibility/TRAINING.md 连接具体代码与运行入口。版本来源、模型加载和检查点清单共同确定本文的评测配置，不能用当前仓库主页的简写标签替代评分定义。

BLiMP 的两种记录存在一处可复核的计分差别。本地运行按所选选项的序号判定正误，两代模型分别记为 68.51 与 68.26；发布的预测文件只保存所选答案文字，按文字与正确答案匹配后，分别得到 68.52 与 68.27，与公开显示一致。67 个子任务、59,875 道题中有 7 道题的两个选项文字相同，分布于 passive_1 与 principle_A_case_2。第一代与第二代分别有 3 道、5 道此类题在两种计分方式下不同，足以复现上述差值；预测文件本身与对应原运行保存的文件一致。results/blimp_scoring_comparison.csv 给出汇总。本文保留各记录的原值，所有本地训练对照仍使用同一计分方式。

任务宏平均与逐题净变化衡量不同对象。记正误指示为 $c_i^{(0)}, c_i^{(1)}$ ，则答对题目的净变化为 $\Delta N = \sum_i (c_i^{(1)} - c_i^{(0)})$ 。子任务样本量不等，两种统计量可以异号；Reading 等非准确率量不纳入题目计数。第一阶段的不同增量尺度之间曾出现这种差别，该结果不描述两代正式模型的逐题变化。

不确定性的计算与测量单位对应：关系实验报告训练种子间的标准差；来源隔离损失以配对文本为单位重采样,同一对中的目标一起抽取;最终结果报告同一母模型的两次续训.GlobalPIQA 的逐题配对区间尚未随本文提供。

AoA 按规定的有效词数和统计条件评价词汇学习轨迹。两代模型共享 17 个前期检查点：1M 至 10M 每 1M 一个，20M 至 80M 每 10M 一个；各加入自身最终模型后，形成 18 点轨迹。两代模型目录中的 CHECKPOINTS.json 列出检查点与实际累计词数，也明确了两条轨迹共享的前期历史。清单按各模型实际停止点配置，不补入它们未经历的 90M 或 100M 分支；使用默认检查点列表运行其他模型时，应相应调整列表，而非改变这里的实际训练轨迹。

B 本地完整评测向量

以下两表列出共同母模型和八个续训模型的全部九项结果，顺序一致。附随 CSV 保留原始精度，文件索引见附录E；构建程序逐行复核九项均值与 Overall。

表 22 本地对照的语言形式、知识、实体与组合分项。Sup. 为 BLiMP Supplement；同一母模型只列一次。

方案	种子	BLiMP	Sup.	EWoK	Entity	COMPS
母模型	—	68.5100	63.6400	50.0200	28.3200	52.0500
普通续训	62064	68.4700	63.6300	49.8300	28.1600	52.0000
普通续训	62065	68.5200	63.6200	49.8100	28.0900	52.0000
密集遮盖、稀疏监督	62064	68.1200	63.0800	49.9500	29.3900	52.1500
密集遮盖、稀疏监督	62065	68.0900	63.0900	49.8200	29.2900	52.1400
密集遮盖、密集监督	62064	68.0600	63.0400	49.9200	29.3700	52.1500
密集遮盖、密集监督	62065	68.0200	63.0900	49.7700	29.4200	52.1500
密集遮盖、稀疏监督+普通输入保持	62064	68.2600	63.2800	49.8200	29.4000	52.1600
密集遮盖、稀疏监督+普通输入保持	62065	68.2200	63.2900	49.7200	29.4500	52.1400

表 23 同一组九个模型的其余分项及完整 Overall。数值保留四位小数，完整精度见附随数据表。

方案	种子	GlobalPIQA	(Super)GLUE	Reading	AoA	Overall
母模型	—	38.5650	68.9457	8.1650	0.0000	42.0240
普通续训	62064	39.5350	68.9885	8.2200	0.0000	42.0926
普通续训	62065	39.5350	69.2733	8.1950	0.0000	42.1159
密集遮盖、稀疏监督	62064	40.0500	68.8878	8.1950	0.0000	42.2025
密集遮盖、稀疏监督	62065	40.0500	68.9349	8.1950	0.0000	42.1789
密集遮盖、密集监督	62064	40.0500	68.5318	8.2200	0.0000	42.1491
密集遮盖、密集监督	62065	40.0500	68.8058	8.2100	0.0000	42.1684
密集遮盖、稀疏监督+普通输入保持	62064	40.0500	69.0477	8.2000	0.0000	42.2464
密集遮盖、稀疏监督+普通输入保持	62065	40.0500	69.0206	8.1950	0.0000	42.2317

其中，稀疏监督与密集监督分别对应 (M, S) 和 (M, M) ，完整方案再加入普通输入保持。 (S, S) 的快速测量不混入完整九项比较。

表 24 主要 Overall 差值。完整方案增加了用于保持的文本呈现。

比较	种子 62064	种子 62065
(M, S) 减普通续训	0.1099	0.0630
完整方案减普通续训	0.1538	0.1158
完整方案减 (M, S)	0.0439	0.0529
完整方案减母模型	0.2224	0.2078

完整方案相对 (M, S) 的 GlobalPIQA 不变，额外收益来自其他分项的净变化，并非每项同步提高。

C 扩展机制、控制与独立发现

C.1 下游微调随机性的补充比较

表25固定母模型及续训种子 62064 的两个训练结果，分别使用微调种子 42、44 进行 (Super)GLUE 评测。它检验相同模型在不同微调随机过程下的表现，区别于重新进行预训练或续训。两种微调设置下，完整方案的均值均高于母模型和 (M, S) 。本文完整九项主表使用微调种子 42；种子 44 的结果仅用于这一补充比较，不拼接成新的 Overall。七个子任务的全部数值见 `results/finetuning_seed_comparison.csv`。

表 25 固定模型、改变下游微调种子的 (Super)GLUE 结果。数值为七个子任务主要指标的等权均值；两种续训方案均采用续训种子 62064。

模型	微调种子 42	微调种子 44
母模型	68.9457	69.3180
密集遮盖、稀疏监督 (M, S)	68.8878	69.3461
密集遮盖、稀疏监督+普通输入保持	69.0477	69.6266

C.2 目标删除与来源隔离

来源外目标是指目标词未出现在配对的那段来源中，不是该词或事实从未被模型见过。在累计曝光 20M 词的模型上，比较删除来源外目标与删除来源内整词匹配目标，前者在来源外内容词上、按分词片段加权的平均预测损失更高。表26区分隔离层次和采样单位。

表 26 来源隔离目标的局部损失差异 (nats)。正值表示删除来源外监督相对删除匹配复制目标，在被测目标上更差。区间按对应记录的重采样单位解释。

测量样本	目标事件	损失差异	95% 区间
来源对隔离、质量筛选	974	0.0796	[0.031, 0.125]
文档隔离、质量筛选	71	0.1141	[-0.063, 0.313]
文档隔离、全部接受目标	1,012	0.0356	[-0.008, 0.076]

来源对隔离排除已用于相应训练的配对，文档隔离进一步排除同一起来源文档中的其他配对。前一种条件观察到对应目标上的损失差异；后一种条件的区间包含零，尚不能确认同样差异。下表则评价 100M 词模型的七项任务表现，与前面的早期局部预测测量共同说明监督删除的作用与范围。

经验替换、共同初始化、关系锚点、字符身份及实体存储的完整论述见第5章。本附录保留主线相关的详细数值与测量更正，避免同一结果在多个位置重复展开。

表 27 100M 词、单种子目标删除实验的七项结果。保留相同紧凑输入，两种删除条件分别移除 48,105 与 48,387 个 BPE token 的监督。GP 为 GlobalPIQA。

条件	BLiMP	Sup.	EWoK	Entity	COMPS	GP	Reading	均值
完整目标	66.87	63.28	53.54	27.75	51.97	35.62	8.240	43.896
删除来源外	65.64	63.73	51.51	26.72	51.60	36.665	8.195	43.437
删除来源内匹配	67.32	59.84	51.93	25.67	51.58	35.09	8.115	42.792

C.3 测量样本与后续更正

研究对象的“未见”需要明确参照。某个样本不在当前续训前缀内，可能已经存在于母模型历史训练流；逐行文本不同，也可能共享同一来源对或文档。后续去重核查发现，一组曾用于普通损失分析的 6,992 行样本与历史训练流重合，因此不再将其作为干净的泛化保持证据。进一步的候选集合还需要区分精确行重合、配对文本重合与文档重合。

本文把样本范围写在相应结果旁：训练行上的新学习效果、当前前缀之外的来源对、来源对隔离与文档隔离各有作用。更正不会自动推翻其他数据身份下的实验，但会改变原结果允许承担的主张。

同样，KL 自比较需要一致的前向随机性，保持分支的额外调用也需要保存并恢复新学习分支的随机数状态。共同初始化、查询相关性、文本重合与前向一致性检查，分别排除了不同来源的实验混淆。相应程序、测量与核查记录和模型一同保留，供后续比较复用。

D 公开前沿的完整分项

两表与表3使用同一个冻结快照，只列两代正式代表模型及八项外部提交，不附排名。模型完整名称及链接在 `results/leaderboard_comparison.csv` 中；发布者按公开账号列示，不推断未公开的学校或机构归属。

表 28 公开条目的语言形式、知识、实体及组合分项。保留网页显示精度。

发布者／模型	BLiMP	Sup.	EWoK	Entity	COMPS
Qiushi Engine / Principle-guided	68.27	63.28	49.82	29.40	52.16
Qiushi Engine / Frontier	68.52	63.64	50.02	28.32	52.05
go76dof / WWM curriculum	67.20	56.01	56.07	28.45	53.57
Serdar404 / RecGPT-10M	73.11	61.73	52.62	16.59	55.43
Wector1 / Wordpiece-24-4	70.20	66.52	52.10	21.82	54.04
gyaudhw / compagg relay	67.85	65.21	53.00	21.47	52.24
gyaudhw / compagg relay (s0)	67.85	65.21	53.00	19.90	52.24
svsatheesh / BabySteps	71.60	63.93	51.94	27.95	53.13
qyxu1994 / instanton-hybrid	72.13	60.86	50.15	19.87	52.96
gyaudhw / synonly (s0)	67.13	62.30	52.28	19.17	52.22

表 29 相同公开条目的其余分项。Reading 与 AoA 不是普通任务准确率，负值按快照原值保留。

发布者／模型	GlobalPIQA	(Super)GLUE	Reading	AoA
Qiushi Engine / Principle-guided	40.05	69.05	8.20	0.00
Qiushi Engine / Frontier	38.56	68.95	8.17	0.00
go76dof / WWM curriculum	39.67	69.79	5.42	0.00
Serdar404 / RecGPT-10M	40.68	66.64	6.92	0.00
Wector1 / Wordpiece-24-4	36.08	69.18	1.84	0.00
gyaudhw / compagg relay	37.59	65.29	5.84	0.00
gyaudhw / compagg relay (s0)	38.65	65.66	5.84	0.00
svsatheesh / BabySteps	36.15	70.44	7.67	-15.10
qyxu1994 / instanton-hybrid	37.14	67.58	6.35	0.00
gyaudhw / synonly (s0)	40.11	66.99	5.82	0.00

总分相近的模型，分项优势仍然不同。语法较高的模型可能在实体跟踪上较弱，NLP 均值最高的模型也未必 Overall 最高。因此，评价两代模型时需要同时保留总分与分项：综合改善已经体现于 Overall，各项得失则帮助解释这种改善来自哪里。

E 配套研究工程与材料使用

配套研究工程按三个阶段与科学问题组织模型、方法、实验和科研记录。读者可从报告中的发现进入相应程序、配置与结果，也可沿专题目录查阅推导、实验规划和后续修正。本附录列出直接入口，全部文件路径均相对于仓库根目录。

模型资源。 [Hugging Face](#): 第一代模型与第二代模型包含权重、分词器、加载实现及训练评测说明，本文采用的具体版本见附录A。

研究材料。 [GitHub: Qiushi-Engine-Babylm-Research](#) 收录两代模型、方法实现、实验配置、数据构造、完整评测、科研笔记与报告源文件。模型包的使用说明见 `models/README.md`，各科学主题的材料见下表。

表 30 报告与研究材料的对应入口。方法说明、执行配置和原始程序各有用途，主要图表数据见表31。

研究内容	材料入口与用途
两代模型与继承关系	<code>models/README.md</code> : 本地权重、分词器、自定义加载实现、训练说明及模型使用示例。
经验构造与增量学习	<code>methods/compact_views.md</code> 、 <code>methods/residual_learning.md</code> : 第一阶段的文本预算与模型设计。
关系学习与能力复用	<code>methods/relation_learning.md</code> 、 <code>methods/functional_access.md</code> : 关系、窗口、监督及内部干预的实验解释。
原理指导的训练与对照	<code>methods/principle_guided_training.md</code> 、 <code>experiments/configs/executed_stage3.json</code> : 完整方案、比较条件及实际执行配置。
训练、机制与评测程序	<code>experiments/CORE_PROGRAMS.md</code> : 原始程序入口； <code>reproducibility/TRAINING.md</code> : 环境、运行参数与数据依赖。
数据生成与训练输入	<code>data/RECONSTRUCTION.md</code> : 配对、压缩、替换、装填和续训文本构造；来源许可见 <code>data/README.md</code> 。
科学问题与设计演进	<code>research/reading_paths.md</code> : 从具体问题进入假设、对照、结果与后续修正； <code>evidence/research_timeline.md</code> : 研究判断的演变。
科研笔记与实验规划	<code>research/notes/README.md</code> : 分析、推导及路线选择； <code>research/plans/README.md</code> : 实验目标、竞争解释、对照设计和判定条件。
测量记录与术语解释	<code>research/documents/README.md</code> : 测量、数据与技术记录； <code>research/terms.md</code> : 原始材料中的英文术语、缩写与实验条件。
独立发现与完整研究目录	<code>research/materials.md</code> : 74 个主题及其方法、笔记、实验和结果； <code>research/catalog.md</code> : 主题概述与结论状态。
结论与证据对应	<code>evidence/claim_evidence_map.md</code> 、 <code>experiments/index.csv</code> : 从主要发现定位方法、结果表和报告章节。

中英文 LaTeX 工程与 PDF 分别位于 `reports/zh/` 与 `reports/en/`，各目录提供阅读与修改说明。两版共用 `results/` 中的结果数据、参考文献与英文科研图。在仓库根目录运行

make report 重建中文 PDF，运行 make report-en 重建英文 PDF，无需模型训练或外部模型调用。

表 31 主要结果数据与报告构建文件。全部路径相对于 GitHub 研究工程根目录。

文件	内容与用途
results/training_strategy_comparison.csv	九个本地模型、全部九项、精确 Overall、续训种子与累计曝光。
results/leaderboard_comparison.csv	同一公开快照的两代代表模型、八项外部提交、模型链接与显示分数；不含排名列。
results/public_model_revisions.csv	两代公开模型及固定仓库修订。
results/relation_context_use.csv	紧凑重述目标上的来源优势变化及三个训练种子标准差。
results/relation_window_controls.csv	同窗与分窗对照，保留训练种子、测量目标数与检查点聚合方式。
results/natural_restatement_transfer.csv	自然重述中的两类目标及三个训练种子的来源优势变化。
results/finetuning_seed_comparison.csv	三种模型在两种微调种子下的七个子任务与 (Super)GLUE 均值。
results/blimp_scoring_comparison.csv	选项序号计分与保存答案文字计分的 BLiMP 对应结果。
results/interface_reach.csv	同一受控功能干预设置下的熟悉／未见准确率及干预读数。
results/state_preservation_readouts.csv	新学习与保持的不同测量集合及所报告读数。
results/compact_budget.csv	紧凑重述、来源与预算再分配的数量。
results/source_disjoint_target_loss.csv	来源对隔离与文档隔离下的目标损失和区间。
results/target_deletion_100m.csv	三个目标删除条件的七项模型结果。
results/late_consolidation_controls.csv	第一阶段晚期续训与增量对照、更新方式和曝光。
results/private_scale_sweep.csv	第一阶段增量尺度选择的历史测量。
results/preservation_gradient_diagnostic.csv	共同目标位置上的保持强度、梯度方向及测量规模。
results/research_catalog.tsv	按科学主题组织的研究目录、结果状态及正文入口。
reports/zh/render.py	数据读取、九项均值检查与矢量统计图生成。
reports/zh/figures/input_supervision.tex	输入遮盖和损失位置示意的可编辑矢量源。
reports/zh/figures/research_lineage.tex	模型继承、方法联系与独立研究分支的矢量源。
reports/zh/build.sh	中文 LaTeX 与参考文献编译入口。

74 个主题共同保留模型方法、机制发现、对照实验与结论修正。科研笔记和实验规划解释问题怎样形成、方法为何改变，以及哪些结果支持后续研究。模型、代码、文档和第三方数据分别适用各自许可；再分发范围及数据获取、构造方式见 data/README.md 与各材料说明。

F 研究主题与成果目录

本目录按科学问题归纳已整理的研究主题。每项列出操作、发现、状态及可点击的研究材料入口，便于从模型方法继续追踪到机制、对照与独立研究分支。“导读”指向正文中的相关讨论，具体实验文件与分析由各主题的材料页列出。相邻主题可以共享实验和材料。

状态说明：“模型方法”已用于相应真实训练；“实验结果”已有指定条件下的测量；“方法与分析工具”提供实验构造、测量或分析方法；“条件性结果”记录尚不稳定或未完成整体评价的观察；“探索性构造”和“尚未运行”保留候选及后续方向；“已撤回”标记后续检查发现无效的原解释。具体数值、比较条件与样本范围见对应章节，详细材料由配套研究工程组织。

模型与表示

主题	关键操作、结论与状态
R01 稀疏路由与前缀记忆	条件性结果。 比较稀疏访问、容量及共同初始化。局部变化未形成稳定的广泛优势；不能以更少活跃参数替代能力比较（导读：第 2 章；研究材料：R01）。
R02 字符、子词与形态通路	条件性结果。 将词面辅助结构与容量和查表参照区分。有限设置中的表面信息收益尚未成为跨种子的广泛优势（导读：第 2 章；研究材料：R02）。
R03 整词与 token 遮盖	实验结果。 固定训练参照比较遮盖粒度，观察配对种子和分项。粒度改变任务取舍，支持具体训练选择，不支持对所有能力的一致排序（导读：第 2 章；研究材料：R03）。
R04 骨干结构与批量控制	实验结果。 比较 BERT 与 DeBERTa 风格组合，并检查批量差异。晚期组合优势不能只由批量解释；位置相关部件尚未被逐项独立归因（导读：第 2 章；研究材料：R04）。
R05 递归式自回归训练	条件性结果。 复现递归训练方案并完成相应评测，检查词覆盖。该设置未达到领先组合；词覆盖差异不足以解释全部性能差异（导读：第 2 章；研究材料：R05）。
R06 词表、深宽与预算	实验结果。 比较不同词表和深宽配置，区分原型与合法重新训练。更高的分词压缩率没有自动形成稳定收益；需同时计入实际训练预算（导读：第 2 章；研究材料：R06）。
R07 频率门控与细粒度表示	探索性构造。 让粗粒度词表示借用细粒度单元，并检查零门控极限。极限实现符合预期，已训练模型未更强；其他门控和种子仍属候选（导读：第 2 章；研究材料：R07）。
R08 成熟配方的组件比较	实验结果。 考察深宽、词表、LAMB 与长度和遮盖课程。单一组件未复现完整组合；研究对象应包含组件间的共同作用（导读：第 2 章；研究材料：R08）。
R09 门控前馈与层权重候选	尚未运行。 保留 GEGLU、注意力门控及层加权的设计方向。记录为候选而非已验证方法，不计入模型实证贡献（导读：第 2 章；研究材料：R09）。

经验构造与压缩

主题	关键操作、结论与状态
R10 对齐重述与对应关系	实验结果。 比较正确对应、错误对应、匹配来源、重复及分窗。关系组织改变学习，但收益随任务而变；正文的后续研究进一步辨明目标类型（导读：第 3.1 节；研究材料：R10）。
R11 紧凑视图与预算再投入	模型方法。 压缩第二视图，把释放词数用于更多配对。增加经验覆盖并形成实际前沿路线；压缩和扩容是需要分辨的两种作用（导读：第 2 章；研究材料：R11）。
R12 邻接、重复与呈现布局	实验结果。 比较内容与相邻关系，检查成块和交替呈现。不同能力方向不一；分词器和窗口设置必须一致（导读：第 3.1 节；研究材料：R12）。
R13 抽取压缩与表达连接	探索性构造。 构造平衡覆盖、较宽覆盖及词汇范围受控的连接文本。词覆盖可以检查，但不能替代语义关系与完整模型收益（导读：第 5.2 节；研究材料：R13）。
R14 规则式改写	条件性结果。 比较真配对、同实体错误对应、来源及打乱参照。短程出现能力取舍，未形成联合增益；可见 token 数仍需匹配（导读：第 5.2 节；研究材料：R14）。

学习目标与监督分配

主题	关键操作、结论与状态
R15 实体提及一致性	条件性结果。 比较真实对应、错误对应与普通整词遮盖。局部真实对应优势未稳定转化为广泛能力收益（导读：第 3 章；研究材料：R15）。
R16 反事实与跨跨度监督	实验结果。 比较真实、错误及无关系条件，检查已有能力。可识别的关系效应与从头学会关系是不同结论（导读：第 3 章；研究材料：R16）。
R17 状态文本与定向遮盖	条件性结果。 围绕状态选择构造训练文本和目标位置对照。目标行为可以改善，同时损伤广泛语言表现，促成新学习与保持的联合检验（导读：第 4 章；研究材料：R17）。
R18 辅助因果目标	条件性结果。 匹配移位目标与梯度范数，比较批量替换和辅助学习。方向相近的梯度没有保证完整模型改善，局部梯度关系不是效果定律（导读：第 5.5 节；研究材料：R18）。
R19 自采样替换词检测	条件性结果。 加入检测目标并分解其梯度影响。短程综合读数出现收益与代价，晚期整体有效性未完成确认（导读：第 5.5 节；研究材料：R19）。
R20 目标加权与监督覆盖	条件性结果。 比较按词均值、覆盖下限与来源外内容加权。局部拟合提高可能伴随广泛代价；等目标预算替换仍需单独检验（导读：第 3 章；研究材料：R20）。
R21 关系枢纽与反事实线索	条件性结果。 匹配监督量，区分关系选择和直接检索。若任务仍可由检索解决，不能据高分证明新的状态选择计算（导读：第 3 章；研究材料：R21）。
R22 梯度交换与投影	探索性构造。 使用中心化四条件比较、方向投影和负例。已观察局部梯度差异，尚未建立长期训练收益（导读：第 5.5 节；研究材料：R22）。
R23 连贯上下文边际损失	条件性结果。 与破坏上下文的负例比较，检查晚期续训。未得到预期行为分离；零系数匹配未完成，不能作完整单因素归因（导读：第 5.5 节；研究材料：R23）。

课程与学习动力学

主题	关键操作、结论与状态
R24 自适应遮盖粒度	实验结果。 在训练轨迹上比较数据与目标的组合。早期排序可能反转，需要把学习阶段纳入方案判断（导读：第 2 章；研究材料：R24）。
R25 数据顺序与发展式课程	实验结果。 使用相同内容随机顺序与发展式顺序，并修正截断。混合方案的有效性不等于课程顺序具有普遍优势（导读：第 2 章；研究材料：R25）。
R26 上下文长度上限	条件性结果。 保持配对剂量，比较长度限制和评测长度。特定 Overall 变化受 AoA 参照影响，七项没有同步改善（研究材料：R26）。
R27 优化器与成熟状态	实验结果。 比较 AdamW、LAMB、成熟阶段切换及信赖比。优化过程中局部数值变化尚不能预测晚期模型结果（导读：第 5.5 节；研究材料：R27）。
R28 检查点平均与重启	实验结果。 比较相邻模型平均、重启和另一个种子。平均未稳定提高单个高分模型；模型选择与方法归因需要分开（导读：第 2 章；研究材料：R28）。
R29 关系剂量与学习成熟度	实验结果。 比较集中、稀疏及角色变化的绑定经验。构造任务可获得能力，弱稀疏真实训练未自动复现；额外预算单列（导读：第 3 章；研究材料：R29）。
R30 持续关系课程候选	尚未运行。 保留持续关系损失、局部与全上下文切换及再提及遮盖。为待检验路线，不作为已取得结果（导读：第 3 章；研究材料：R30）。

残差结构与增量学习

主题	关键操作、结论与状态
R31 零初始化瓶颈支路	模型方法。 检查共享参数、禁用支路与训练轨迹。初始化和关闭时保持原函数，联合训练仍更新基座（导读：第 2 章；研究材料：R31）。
R32 主辅路径分离	实验结果。 由宽辅助学习转向稀疏辅助、主路径关闭辅助时的比较。早期收益没有直接延续到成熟模型，促成普通连贯重放（导读：第 2 章；研究材料：R32）。
R33 冻结基座的专用增量	模型方法。 仅训练新增参数，使用普通预测与 KL，比较连贯及破坏输入。形成第一代模型；关闭分支可恢复基座，开启时保持仍需评测（导读：第 2 章；研究材料：R33）。
R34 模型谱系与尺度选择	方法与分析工具。 分开连续装填分支、主模型、增量分支与发布尺度。实际权重继承不等于全部路线都串行进入最终模型（导读：第 5 章；研究材料：R34）。

实体记忆与寻址

主题	关键操作、结论与状态
R35 给定地址的写入和读取	实验结果。 比较一致地址置换、错误地址、覆盖与槽交换。存储信号具有功能作用，自然语言寻址不由金标准地址结果证明（导读：第 5.4 节；研究材料：R35）。

主题（续）	关键操作、结论与状态
R36 小型绑定任务的答案捷径	已撤回。 后续检查发现答案不随查询对象改变。原高分不再承担组合绑定结论；修正语料不等于重新训练验证（导读：第 5.4 节；研究材料：R36）。
R37 自然文本到地址的路由	实验结果。 比较原始、词面、循环和离散路由与正确地址。高总体 token 准确率掩盖关键查询召回为零，定位寻址瓶颈（导读：第 5.4 节；研究材料：R37）。
R38 指针与复制初始化	探索性构造。 测试小型指针、嵌入与复制行为初始化。能够复制不等于能够选择正确实体状态（导读：第 5.4 节；研究材料：R38）。

选择与读取

主题	关键操作、结论与状态
R39 格式预适应与标签对齐	实验结果。 比较对齐、打乱和无关标签的准备过程。多种准备都可帮助后续学习，不能仅归因于唯一的对应信号（导读：第 5.4 节；研究材料：R39）。
R40 冻结读取器与组内选择	实验结果。 用四候选组内 softmax 学习选择，分别测词面、角色和时间语义。词面及角色交换近乎完整，原先与更新状态选择仍弱（导读：第 5.4 节；研究材料：R40）。

关系结构与身份

主题	关键操作、结论与状态
R41 关系规则的可识别性	实验结果。 改变初始拥有者并构造平衡反例。训练高分可能来自反拷贝捷径，反事实用于识别目标规则（导读：第 5.3 节；研究材料：R41）。
R42 二值关系图与稀疏锚点	实验结果。 比较共享与分离表示，反转锚点并测量相对关系是否保留，采用多个训练种子。绝对方向可沿共享路径传递，相对关系保持；结论限于给定假设类（导读：第 5.3 节；研究材料：R42）。
R43 字符身份与关系接入	实验结果。 通过字母等同监督学习匹配，再接入共享关系结构。覆盖基础字母支持新组合；候选和硬分配已给定，删边还改变训练量（导读：第 5.3 节；研究材料：R43）。
R44 无泄漏图与程序构造	探索性构造。 生成中性、反向和程序结构任务，并检查类别与先验。候选产率及类型平衡仍有限，不据原型宣称一般推理能力（导读：第 5.3 节；研究材料：R44）。

条件化经验价值

主题	关键操作、结论与状态
R45 结构密度与表示恢复	条件性结果。 比较不同结构密度、残差条件与随机参照。局部结构读数恢复没有保证广泛收益，不能与容量混淆（导读：第 5.2 节；研究材料：R45）。
R46 共享来源簇的尾段训练	条件性结果。 比较真实、打乱、重复及普通经验。优于错配不等于优于所有参照，未完成全部模型测量（导读：第 5.2 节；研究材料：R46）。
R47 固定预算的视图、广度与重复	实验结果。 在共同预算下替换经验，并保留晚期多个模型。晚期收益依赖经验类型与架构；不同句子扩展不等于文档扩容（导读：第 5.2 节；研究材料：R47）。
R48 语域替换与数据价值预测	实验结果。 固定加入内容，改变移除语域，比较词分布与任务读数。替代对象的机会成本不同；不同测量设置之间不能直接验证同一个预测（导读：第 5.2 节；研究材料：R48）。
R49 显式关系文本的筛选	探索性构造。 比较显式关系与随机质量参照，过滤自然状态文本。合格候选有限，短程结果不能当作成熟大规模训练流（导读：第 5.2 节；研究材料：R49）。

监督目标与来源

主题	关键操作、结论与状态
R50 来源外与复制目标删除	实验结果。 保留输入并近匹配删除目标量，分来源对和文档隔离。局部来源对结果成立，更严格文档隔离区间跨零；全任务排序不同（导读：第 3 章；研究材料：R50）。
R51 正确、错误与缺失来源	实验结果。 固定目标 token，改变来源条件。来源效应也可能在未加新监督时存在，不能直接视为最终模型提高的直接原因（导读：第 3.1 节；研究材料：R51）。
R52 覆盖、顺序与局部上下文	方法与分析工具。 区分来源存在、前缀、间隔与文本在窗口中的相对位置。加载身份未完全确认的比较仅用于说明几何，不用于确认具体机制效果（导读：第 3.1 节；研究材料：R52）。

功能机制与学习信号

主题	关键操作、结论与状态
R53 有序组合与动态绑定	实验结果。 比较动态、静态关系、局部和最终监督，并检查读出。从表示可解码的信息不一定是模型实际执行的计算（导读：第 3.2 节；研究材料：R53）。
R54 上下文隐藏状态与干预	实验结果。 比较一致前缀、错配、实体替换和激活替换。主题信息可存在而状态执行仍失败，需要行为与功能共同检验（导读：第 3.2 节；研究材料：R54）。

主题 (续)	关键操作、结论与状态
R55 微型世界的状态更新	方法与分析工具。 控制状态、行动、矛盾、答案线索与覆盖。提供机制检验工具，不自动证明自然文本中已形成相同选择器（导读：第 3.2 节；研究材料：R55）。
R56 梯度冲突与学习信号估计	条件性结果。 使用相同材料、跨配对与留出对象的比较。局部相关性未成为稳定的前瞻收益预测（导读：第 5.5 节；研究材料：R56）。
R57 对比预测与辅助读出	条件性结果。 比较同来源、跨来源和困难负例。辅助目标拟合或饱和不充分说明新能力形成（导读：第 5.5 节；研究材料：R57）。
R58 分层读出与位置编辑	条件性结果。 使用双线性、岭回归、旋转空对照和局部编辑。局部拟合不保证留出迁移，有限编辑示例不承担广泛机制结论（导读：第 3.2 节；研究材料：R58）。
R59 配对交换下的分数变化	方法与分析工具。 检查类别、打乱和长度交换等匹配条件。分数中的代数抵消，不等于模型实际利用了对应关系（导读：第 5.5 节；研究材料：R59）。

测量、迁移与归因

主题	关键操作、结论与状态
R60 共同参数初始化	方法与分析工具。 显式复制共同张量，分别测结构绝对能力与数据相对效果。同一随机种子不保证同初值；修正后较大的交互解释显著减弱（导读：第 5.5 节；研究材料：R60）。
R61 宏平均与逐题变化	方法与分析工具。 分别计算获得、损失、净变化及互补题目。宏平均和净正确数可以异号，不能只用一个总分描述能力变化（导读：第 5.5 节；研究材料：R61）。
R62 迁移条件与表示几何	条件性结果。 比较种子条件、主成分和随机参照。相关性和径向增长未建立能力守恒或普遍迁移规律（导读：第 5.5 节；研究材料：R62）。
R63 完整评测与模型接口	方法与分析工具。 核对加载实现、AoA 轨迹、常识及阅读评分。缺失、零分和公开显示值分别处理，完整模型身份决定可比性（导读：附录 A.4；研究材料：R63）。

系统与计算

主题	关键操作、结论与状态
R64 词边界、装填与可见预算	方法与分析工具。 检查配对完整性、截断及连续窗口实际呈现。记账词数与可见内容需要对应，原型和最终分词实现不能混用（导读：第 5.5 节；研究材料：R64）。
R65 微批量与梯度等价	方法与分析工具。 按目标数量加权，在固定随机条件下检查激活重计算前后的梯度一致性。验证有限实现条件，不声称完整随机训练轨迹完全相同（导读：第 5.5 节；研究材料：R65）。
R66 模型重建与成本分层	方法与分析工具。 固定权重、配置与代码身份，分开训练和搜索成本。重建同种子、跨种子重复与计算节约是不同结论（导读：附录 A；研究材料：R66）。

主线的深化与实践检验

主题	关键操作、结论与状态
R67 训练关系的选择性	实验结果。 在三个种子上比较逐字重复与对齐重述的来源优势。对紧凑改写目标产生不同方向的效果，不支持重复普遍有害（导读：第 3.1 节；研究材料：R67）。
R68 同材料的预测窗口	实验结果。 分别把重复配对和重述配对拆分到不同窗口。较大来源效应明显减弱；同内容控制发生在各配对的同窗与分窗之间（导读：第 3.1 节；研究材料：R68）。
R69 自然改写的迁移条件	实验结果。 按目标的分词编号是否出现在来源中，对自然重述目标分组。对齐重述提高了来源中已有 token 的来源利用优势；没有同一 token 的目标未出现同样稳定的收益。分组表示词面重合，不表示语义是否新颖（导读：第 3.1 节；研究材料：R69）。
R70 熟悉表现与未见调用	实验结果。 比较普通、静态权重和交替监督的续训。熟悉行为恢复不保证未见符号的调用范围恢复（导读：第 3.2 节；研究材料：R70）。
R71 功能信号的抹除与搬移	实验结果。 对属性位置信号中心化、置零、旋转，并检验重新拟合方向。支持具体信号的功能作用，未恢复的线性方向不排除全部分布式重编码（导读：第 3.2 节；研究材料：R71）。
R72 密集输入与稀疏监督	模型方法。 沿用既有文本，分别控制遮盖候选和聚焦目标。同曝光下两种子完整评测均优于普通续训；该比较不是单一遮盖因子（导读：第 4 章；研究材料：R72）。
R73 保持输入与有效强度	实验结果。 固定共同目标位置测保持梯度，并比较普通与密集输入。相同系数下梯度大小仍相差约 12 倍；完整比较还改变目标位置集合（导读：第 4 章；研究材料：R73）。
R74 原理指导的完整模型	模型方法。 同一母模型上复核普通续训、关系学习及完整保持方案。完整方案在两个续训种子上均改善九项 Overall，额外呈现与计算单列（导读：第 4.4 节；研究材料：R74）。

参考文献

-
- [1] Niklas Muennighoff, Alexander M. Rush, Boaz Barak, Teven Le Scao, Aleksandra Piktus, Nouamane Tazi, Sampo Pyysalo, Thomas Wolf, and Colin Raffel. Scaling Data-Constrained Language Models. *Journal of Machine Learning Research*, 26(53):1–66, 2025. URL <http://jmlr.org/papers/v26/24-1000.html>.
 - [2] Alex Warstadt, Aaron Mueller, Leshem Choshen, Ethan Wilcox, Chengxu Zhuang, Juan Ciro, Rafael Mosquera, Bhargavi Paranjape, Adina Williams, Tal Linzen, and Ryan Cotterell. Findings of the BabyLM Challenge: Sample-Efficient Pretraining on Developmentally Plausible Corpora. In *Proceedings of the BabyLM Challenge at the 27th Conference on Computational Natural Language Learning*, pages 1–34. Association for Computational Linguistics, 2023. doi: 10.18653/v1/2023.conll-babylm.1. URL <https://aclanthology.org/2023.conll-babylm.1/>.
 - [3] BabyLM Organizing Team. BabyLM Challenge 2026. Official challenge website, 2026. URL <https://babylm.github.io/>. Accessed 8 September 2026.
 - [4] Lucas Charpentier, Leshem Choshen, Ryan Cotterell, Mustafa Omer Gul, Michael Y. Hu, Jing Liu, Jaap Jumelet, Tal Linzen, Aaron Mueller, Candace Ross, Raj Sanjay Shah, Alex Warstadt, Ethan Gottlieb Wilcox, and Adina Williams. Findings of the Third BabyLM Challenge: Accelerating Language Modeling Research with Cognitively Plausible Data. In *Proceedings of the First BabyLM Workshop*, pages 399–420. Association for Computational Linguistics, 2025. doi: 10.18653/v1/2025.babylm-main.28. URL <https://aclanthology.org/2025.babylm-main.28/>.
 - [5] Leshem Choshen, Ryan Cotterell, Mustafa Omer Gul, Jaap Jumelet, Tal Linzen, Aaron Mueller, Suchir Salhan, Raj Sanjay Shah, Alex Warstadt, and Ethan Gottlieb Wilcox. BabyLM Turns 4 and Goes Multilingual: Call for Papers for the 2026 BabyLM Workshop. *arXiv preprint arXiv:2602.20092*, 2026. URL <https://arxiv.org/abs/2602.20092>.
 - [6] Alex Warstadt, Alicia Parrish, Haokun Liu, Anhad Mohanane, Wei Peng, Sheng-Fu Wang, and Samuel R. Bowman. BLiMP: The Benchmark of Linguistic Minimal Pairs for English. *Transactions of the Association for Computational Linguistics*, 8:377–392, 2020. doi: 10.1162/tac1_a_00321. URL <https://aclanthology.org/2020.tac1-1.25/>.
 - [7] Anna A. Ivanova, Aalok Sathe, Benjamin Lipkin, Unnathi U. Kumar, Setayesh Radkani, Thomas H. Clark, Carina Kauf, Jennifer Hu, R. T. Pramod, Gabriel Grand, Vivian C. Paulun, Maria Ryskina, Ekin Akyürek, Ethan G. Wilcox, Nafisa Rashid, Leshem Choshen, Roger Levy, Evelina Fedorenko, Joshua Tenenbaum, and Jacob Andreas. Elements of World Knowledge (EWoK): A Cognition-Inspired Framework for Evaluating Basic World Knowledge in Language Models. *Transactions of the Association for Computational Linguistics*, 13:1245–1270, 2025. doi: 10.1162/tac1.a.38. URL <https://aclanthology.org/2025.tac1-1.57/>.
 - [8] Kanishka Misra, Julia Rayz, and Allyson Ettinger. COMPS: Conceptual Minimal Pair Sentences for testing Robust Property Knowledge and its Inheritance in Pre-trained Language Models. In *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 2928–2949. Association for Computational Linguistics, 2023. doi: 10.18653/v1/2023.eacl-main.213. URL <https://aclanthology.org/2023.eacl-main.213/>.
 - [9] Najoung Kim and Sebastian Schuster. Entity Tracking in Language Models. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 3835–3855. Association for Computational Linguistics, 2023. doi: 10.18653/v1/2023.acl-long.213. URL <https://aclanthology.org/2023.acl-long.213/>.
 - [10] Tyler A. Chang, Catherine Arnett, Abdelrahman Sadallah, et al. Global PIQA: Evaluating commonsense reasoning across 100+ languages and cultures, 2025. URL <https://arxiv.org/abs/2510.24081v2>. Version 2, 29 May 2026; first submitted 28 October 2025.
 - [11] BabyLM Organizing Team. BabyLM Evaluation 2026. Official evaluation repository; Strict and Strict-Small implementation, 2026. URL <https://github.com/babylm-org/babylm-eval/tree/6f825c291e2c4c78ad33b1935fd64d45f52642dc/strict>. Reference scoring revision 6f825c2; accessed 8 September 2026. Model-specific loading and checkpoint configuration are described in Appendix A.
 - [12] Alex Wang, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, and Samuel R. Bowman. GLUE: A multi-task benchmark and analysis platform for natural language understand-

- ing. In *Proceedings of the 2018 EMNLP Workshop BlackboxNLP: Analyzing and Interpreting Neural Networks for NLP*, pages 353–355. Association for Computational Linguistics, 2018. doi: 10.18653/v1/W18-5446. URL <https://aclanthology.org/W18-5446/>.
- [13] Alex Wang, Yada Pruksachatkun, Nikita Nangia, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, and Samuel Bowman. SuperGLUE: A Stickier Benchmark for General-Purpose Language Understanding Systems. In *Advances in Neural Information Processing Systems*, volume 32. Curran Associates, Inc., 2019. URL https://proceedings.neurips.cc/paper_files/paper/2019/file/4496bf24afe7fab6f046bf4923da8de6-Paper.pdf.
- [14] Andrea Gregor de Varda, Marco Marelli, and Simona Amenta. Cloze probability, predictability ratings, and computational estimates for 205 English sentences, aligned with existing EEG and reading time data. *Behavior Research Methods*, 56:5190–5213, 2024. doi: 10.3758/s13428-023-02261-8. URL <https://link.springer.com/article/10.3758/s13428-023-02261-8>. First published online 25 October 2023.
- [15] BabyLM Community. BabyLM Leaderboard 2026. Official Hugging Face Space and public source code, 2026. URL <https://huggingface.co/spaces/BabyLM-community/BabyLM-Leaderboard-2026>. Aggregation and sorting source: revision c84d8c1. Public Strict-Small table retrieved 8 September 2026, 12:53 UTC; 129 records. Comparisons use Overall sorting.
- [16] Tyler A. Chang and Benjamin K. Bergen. Word acquisition in neural language models. *Transactions of the Association for Computational Linguistics*, 10:1–16, 2022. doi: 10.1162/tac1_a_00444. URL <https://aclanthology.org/2022.tac1-1.1/>.
- [17] Pengcheng He, Xiaodong Liu, Jianfeng Gao, and Weizhu Chen. DeBERTa: Decoding-enhanced BERT with Disentangled Attention. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=XPZlaotutsD>.
- [18] Microsoft. DeBERTa: Official implementation and DeBERTa-v2 release notes. Official implementation repository, 2021. URL <https://github.com/microsoft/DeBERTa#whats-new-in-v2>. Version 2 release notes dated 3 February 2021; accessed 9 September 2026.
- [19] Thomas Bachlechner, Bodhisattwa Prasad Majumder, Henry Mao, Gary Cottrell, and Julian McAuley. ReZero is all you need: fast convergence at large depth. In *Proceedings of the Thirty-Seventh Conference on Uncertainty in Artificial Intelligence*, volume 161 of *Proceedings of Machine Learning Research*, pages 1352–1361. PMLR, 2021. URL <https://proceedings.mlr.press/v161/bachlechner21a.html>.
- [20] Neil Houlsby, Andrei Giurgiu, Stanislaw Jastrzebski, Bruna Morrone, Quentin De Laroussilhe, Andrea Gesmundo, Mona Attariyan, and Sylvain Gelly. Parameter-Efficient Transfer Learning for NLP. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 2790–2799. PMLR, 2019. URL <https://proceedings.mlr.press/v97/houlsby19a.html>.
- [21] Weijia Shi, Sewon Min, Maria Lomeli, Chunting Zhou, Margaret Li, Gergely Szilvasy, Rich James, Xi Victoria Lin, Noah A. Smith, Luke Zettlemoyer, Scott Yih, and Mike Lewis. In-context Pretraining: Language Modeling Beyond Document Boundaries. In *International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=LXVswInH0o>.
- [22] Stephanie Chan, Adam Santoro, Andrew Lampinen, Jane Wang, Aaditya Singh, Pierre Richemond, James L. McClelland, and Felix Hill. Data Distributional Properties Drive Emergent In-Context Learning in Transformers. In *Advances in Neural Information Processing Systems*, volume 35, pages 18878–18891. Curran Associates, Inc., 2022. doi: 10.52202/068431-1371. URL https://proceedings.neurips.cc/paper_files/paper/2022/file/77c6ccacf9962e2307fc64680fc5ace-Paper-Conference.pdf.
- [23] Akari Haga, Akiyo Fukatsu, Miyu Oba, Arianna Bisazza, and Yohei Oseki. BabyLM Challenge: Exploring the effect of variation sets on language model training efficiency. In *The 2nd BabyLM Challenge at the 28th Conference on Computational Natural Language Learning*, pages 252–261. Association for Computational Linguistics, 2024. URL <https://aclanthology.org/2024.conll-babyLM.23/>.
- [24] Yanda Chen, Chen Zhao, Zhou Yu, Kathleen McKeown, and He He. Parallel structures in pre-training data yield in-context learning. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 8582–8592. Association for Computational Linguistics, 2024. doi: 10.18653/v1/2024.acl-long.465. URL

- <https://aclanthology.org/2024.acl-long.465/>.
- [25] Nicolas Zucchet, Francesco D’Angelo, Andrew Kyle Lampinen, and Stephanie Chan. The emergence of sparse attention: impact of data distribution and benefits of repetition. In *Advances in Neural Information Processing Systems*, volume 38, pages 39439–39476. Curran Associates, Inc., 2025. doi: 10.52202/085713-1179. URL https://proceedings.neurips.cc/paper_files/paper/2025/hash/323b34ddc3b1787a685f4664d8dbb76c-Abstract-Conference.html.
 - [26] Atticus Geiger, Hanson Lu, Thomas Icard, and Christopher Potts. Causal Abstractions of Neural Networks. In *Advances in Neural Information Processing Systems*, volume 34, pages 9574–9586. Curran Associates, Inc., 2021. URL https://proceedings.neurips.cc/paper_files/paper/2021/file/4f5c422f4d49a5a807eda27434231040-Paper.pdf.
 - [27] Fred Zhang and Neel Nanda. Towards Best Practices of Activation Patching in Language Models: Metrics and Methods. In *International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=Hf17y6u9BC>.
 - [28] Aaditya Singh, Stephanie Chan, Ted Moskovitz, Erin Grant, Andrew Saxe, and Felix Hill. The Transient Nature of Emergent In-Context Learning in Transformers. In *Advances in Neural Information Processing Systems*, volume 36, pages 27801–27819. Curran Associates, Inc., 2023. doi: 10.52202/075280-1208. URL https://proceedings.neurips.cc/paper_files/paper/2023/file/58692a1701314e09cbd7a5f5f3871cc9-Paper-Conference.pdf.
 - [29] Suraj Anand, Michael A. Lepori, Jack Merullo, and Ellie Pavlick. Dual process learning: Controlling the use of in-context vs. in-weights strategies with weight forgetting. In *The Thirteenth International Conference on Learning Representations*, 2025. URL https://proceedings.iclr.cc/paper_files/paper/2025/hash/7db2348b5bfeca620aa7327df815adcc-Abstract-Conference.html.
 - [30] Alexander Wettig, Tianyu Gao, Zexuan Zhong, and Danqi Chen. Should you mask 15% in masked language modeling? In *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 2985–3000. Association for Computational Linguistics, 2023. doi: 10.18653/v1/2023.eacl-main.217. URL <https://aclanthology.org/2023.eacl-main.217/>.
 - [31] Zhizhong Li and Derek Hoiem. Learning without forgetting. In *Computer Vision – ECCV 2016*, volume 9908 of *Lecture Notes in Computer Science*, pages 614–629. Springer, 2016. doi: 10.1007/978-3-319-46493-0_37. URL https://link.springer.com/chapter/10.1007/978-3-319-46493-0_37.
 - [32] Jiahai Feng and Jacob Steinhardt. How do Language Models Bind Entities in Context? In *International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=zb3b6oK077>.
 - [33] Qin Dai, Benjamin Heinzerling, and Kentaro Inui. Representational Analysis of Binding in Language Models. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 17468–17493. Association for Computational Linguistics, 2024. doi: 10.18653/v1/2024.emnlp-main.967. URL <https://aclanthology.org/2024.emnlp-main.967/>.
 - [34] Shuxing Yang, Fujia Chen, Rui Zhao, Junyao Wu, Yize Wang, Haiyao Luo, Ning Han, Qiaolu Chen, Yuze Hu, Wenhao Li, Mingzhu Li, Hongsheng Chen, and Yihao Yang. End-to-end autonomous scientific discovery on a real optical platform. *arXiv preprint arXiv:2604.27092*, 2026. URL <https://arxiv.org/abs/2604.27092>.
 - [35] Chris Lu, Cong Lu, Robert Tjarko Lange, Yutaro Yamada, Shengran Hu, Jakob Foerster, David Ha, and Jeff Clune. Towards end-to-end automation of AI research. *Nature*, 651:914–919, 2026. doi: 10.1038/s41586-026-10265-5. URL <https://www.nature.com/articles/s41586-026-10265-5>.
 - [36] Eric Zelikman, Eliana Lorch, Lester Mackey, and Adam Tauman Kalai. Self-taught optimizer (STOP): Recursively self-improving code generation. In *First Conference on Language Modeling*, 2024. URL <https://openreview.net/forum?id=46Zgqo4QIU>.
 - [37] Jenny Zhang, Shengran Hu, Cong Lu, Robert Lange, and Jeff Clune. Darwin Gödel machine: Open-ended evolution of self-improving agents. In *The Fourteenth International Conference on Learning Representations*, 2026. URL <https://openreview.net/forum?id=pUpzQZTvGY>.
 - [38] Noah Shinn, Federico Cassano, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. Reflexion: Language agents with verbal reinforcement learning. In *Advances in Neural Information Processing Systems*, volume 36, 2023. URL https://proceedings.neurips.cc/paper_files/paper/2023/hash/1b44b878bb782e6954cd888628510e90-Abstract-Conference.html.

- [39] Juraj Gottweis, Wei-Hung Weng, Alexander Daryin, et al. Accelerating scientific discovery with Co-Scientist. *Nature*, 655:487–496, 2026. doi: 10.1038/s41586-026-10644-y. URL <https://www.nature.com/articles/s41586-026-10644-y>.
- [40] Mingguang Chen, Licheng Wang, and Bo Qu. Recursive self-improvement in AI: From bounded self-refinement to autonomous research loops. *arXiv preprint arXiv:2607.07663*, 2026. URL <https://arxiv.org/abs/2607.07663v2>.